

Betydningen af et netværk i udviklingen af en objektgenkendelsesmodel til detektering og klassificering af pollen partikler: Transparens og efterlignelighed gennem open-source.

Projekt titel:

Betydningen af et netværk i udviklingen af en objektgenkendelsesmodel til detektering og klassificering af pollen partikler: Transparens og efterlignelighed gennem open-source.

Gruppe medlemmer:

Magnus Hartø Trojahn (studie num.: 71389) - hartoe@ruc.dk

Maurits Villas Jeppesen Puggaard (studie num.: 71425) - mvjp@ruc.dk

Martin Jarner Vasegaard Jørgensen (studie num.: 71801) - mjvj@ruc.dk

Mohamad Nakli Dit Aldaoudi (studie num.: 71351) - mnda@ruc.dk

Marcus Rønnow Stjernø (studie num.: 71370) - marost@ruc.dk

Mohamad Moaz Ahmad Abdullatif (studie num.: 72011) - moaz@ruc.dk

Vejleder:

Alfred Birkegaard - mail: albiha@ruc.dk

Linje: HumTek

Abstract

Currently, Astma-Allergi Danmark, as an organization, is responsible for manually collecting pollen data across Denmark. However, there is potential for improvement through the application of AI and machine learning. Due to a lack of collaboration with Astma-Allergi Danmark, this project aims to investigate the collection methods of pollen and develop an attempt to create an image recognition AI that can automate the organization's manual processes. Given the limited knowledge and cooperation regarding their internal systems, the projekt relies on building networks with external partners to establish a knowledge base. The project's perspective focuses on creating an open-source machine learning model and process, allowing future researchers to work with machine learning in the field of microscopy. To address our model, we aim to explore various aspects of machine learning, specifically focussing on the YOLOv8 model. We will provide insights into how the pollen counting process can be enhanced and discuss our decisions to create our own dataset. Furthermore the theory behind data preprocessing, digitalizing microscope images, and training an object recognition model will be described. We will aim to explain how we facilitated the development of our final product through the SCRUM framework and an iterative design approach involving multiple prototypes and highlight the learning points derived from them. Based on our product and the development of it, we will critically analyze and discuss the result produced by the model, encompassing both technical and practical evaluations, but also our network and its impact on the project. This project aims to contribute with a machine learning model, a comprehensive explanation of its development, and the knowledge applicable to future projects of a similar nature. Finally, we draw conclusions and provide answers to the key points addressed in our problem-formulation and research questions, aiming to address the research problem effectively.

Indholdsfortegnelse

ABSTRACT	2
INDLEDNING.....	5
MOTIVATION.....	6
PROBLEMFELT.....	8
PROBLEMFORMULERING.....	8
ARBEJDSSPØRGSMÅL.....	9
AFGRÆNSNING.....	11
REDEGØRELSE	12
PROBLEM OPRINDELSE	12
<i>Astma-Allergi Danmark</i>	12
<i>Pollentyper og indsamling</i>	13
<i>FabLab</i>	14
<i>HumTek</i>	15
<i>Eksterne samarbejdspartnere</i>	16
TEORI	19
OPEN SOURCE.....	19
PROJEKTSTYRING	20
<i>Scrum</i>	21
<i>Jira</i>	23
<i>Iterativ process</i>	23
<i>Prototyping</i>	25
TEKNISK TEORI.....	25
<i>Machine Learning</i>	25
Supervised vs unsupervised learning.....	26
Objektgenkendelse & YOLOv8.....	28
Overfitting og underfitting.....	30
Data preprocessing.....	31
Roboflow.....	33
<i>Trin-modellen</i>	34
VIDENSBIDRAG.....	35
<i>Netværksteori</i>	36
3XA.....	36
Anti-diciplinær videnskab.....	37

Kollaboration, Kooperation	38
Pollen samfundet.....	40
METODE	43
POLLEN INDSAMLING.....	43
PROTOTYPER	46
<i>Machine learning modellen</i>	46
Iteration 1	47
Koden.....	47
Iteration 2	52
<i>Pollen digitalisering</i>	56
Iteration 1	56
Iteration 2	57
Iteration 3	58
ENDELIGT PRODUKT OG MODEL	59
ANALYSE OG RESULTATER.....	61
PRODUKTANALYSE.....	61
<i>Teknisk evaluering</i>	61
<i>Praktisk evaluering</i>	69
<i>Analyse af trin-modellen</i>	71
PROJEKTSTYRINGS ANALYSE	73
<i>Hvordan har vi brugt SCRUM til at facilitere vores iterative proces</i>	73
NETVÆRKSTEORI / HVORDAN ER VORES VIDENSBIDRAG	75
Anti-disiplinær videnskab i projektet.....	76
<i>Hvordan bruger vi vores netværk</i>	76
Triple A model	77
Kollaboration, Kooperation	79
DISKUSSION	81
PRODUKT DISKUSSION.....	81
Produktets bidrag	82
NETVÆRK.....	84
<i>Agil udvikling vs Kollaborativ udvikling</i>	84
<i>Hvor stor betydning har vores netværk på projektet</i>	86
<i>Pollensamfundet</i>	88
KONKLUSION.....	90
REFERENCER.....	92

Indledning

På nuværende tidspunkt står Astma-allergi Danmark for at samle Danmarks pollental i form af manuelle processer, der kunne forestilles at blive forbedret i form af AI og machine learning. Grundet et manglende samarbejde med Astma-allergi Danmark, vil projektet derfor undersøge hvordan man, i form af indsamlingsmetoder af pollen, samle et datasæt og herpå udvikle et forsøg på at lave en billede-genkendelses AI, der kan gøre astma-allergi danmarks manuelle metoder automatiseret. Grundet manglende samarbejde, og manglende viden på deres arbejdsprocesser, ønsker projektet derfor kun at give et gæt på hvordan sådan en model ville se ud. Den manglende viden på interne systemer for at sådan en model ville kunne opbygges, leder derfor projektet til at opbygge netværk gennem eksterne samarbejdspartnere, hvorpå et vidensgrundlag kan opbygges til projektet. Denne vinkel på projektet vil derfor rette sig imod at lave machine learning-modellen, og processen, open-source, hvorpå alle, der ønsker at arbejde med machine learning under mikroskop i fremtiden, ville have mulighed for dette.

For at løse vores problemformulering gennemgår vi forskellige aspekter af hvad machine learning er, samt den type vi vælger at bruge, nemlig YOLOv8. Vi forsøger at give et bud på hvordan man kan forbedre pollentællingsprocessen, og vi gennemgår vores beslutninger om selv at lave et datasæt. Vi beskriver teorien bag hvad præprocessering af data er, og hvordan man kan digitalisere et mikroskop via billeder, samt hvordan man træner en objektgenkendelsesmodel.

Vi beskriver hvordan vi har faciliteret udviklingen af vores endelige produkt, gennem SCRUM og hvordan vi har designet iterativt ved at lave adskillige prototyper. Vi gennemløber vores prototyper og beskriver læringspunkterne som de hver har bragt.

På baggrund af vores projekt, samt udvikling af produkt, analyserer og diskuterer vi vores resultater som modellen producerer, både en teknisk- og praktisk evaluering, samt laver en kritisk analyse og diskussion af vores netværk og dens indflydelse på projektet. Vi tilskriver projektet det formål at være retningsgivende for lignende projekter, og holder derfor centralt for rapporten, hvordan forskellige aspekter af projektets situation, som netværket, men også arbejdsdeling og projektstyring, har formende karakter for vores projekt. Projektet bidrager med en Machine Learning model, en gennemgang af hvordan

den er udviklet samt viden til lignende projekters udførelse i fremtiden. Endegyldigt vil der konkluderes, og giver svar på hovedpointerne i arbejdsspørgsmålene, som vi stiller for at besvare problemformuleringen.

Motivation

Dette afsnit er inkluderet for at give kontekst for projektets udarbejdelse, samt at berøre hvilke fagområder der vil blive uddybet og benyttet gennem det. Der vil blive nævnt vores motivation og en kort udviklingshistorie af de konkrete til og fravalg, der er taget i forhold til projektet.

Vores projekt blev i første omgang inspireret af en fremlæggelse fra Fablab, hvor Bo Thorning, som senere blev vores tekniske vejleder, havde brugt artificial intelligence til blodcelledetektering under mikroskop, og klassificering med en objektgenkendelse model. Her var det især sammenkoblingen af en reel, virkelighedsbaseret problemstilling og det teknologiske AI aspekt vi fandt interessant.

Da vi som HumTek studerende er underlagt problemorienteret projektlæring, var det oplagt at finde en lignende relevant virkelighedsbaseret problemstilling, vi kunne udforske. Derfor valgte vi en case, hvor sammenkoblingen af artificial intelligence med reel detektion og klassificerings opgaver også var relevant, nemlig optælling af pollental. FabLab's tilgang til vidensdannelse og HumTek-bachelorens sammensætning gav os mulighed for at udforske og stille spørgsmål uden at være begrænset til en enkelt teknologi eller fagområde. Vi undersøgte derfor hvilke virksomheder der kunne opfylde de krav, og fandt i den sammenhæng ud af, at Astma Allergi Danmarks pollenoptællingsmetode er overordnet manuel, og af den grund er en oplagt kandidat til vores ønske om at automatisere en process gennem kunstig intelligens.

Traditionelt kræver feltet med AI og analyse af pollen avanceret udstyr og specialiseret ekspertise. Dette har skabt en barriere for adgang til denne type teknologi for mange mennesker og begrænset dens anvendelse i bredere sammenhænge. Ved at anvende DIY- og open-source-tilgange, forsøger vi at nedbryde disse barrierer og gøre teknologien mere tilgængelig. Af den grund spiller Fablab-miljøet en væsentlig rolle i vores tilgang. Fablabs

åbne værksted giver adgang til moderne produktionsværktøjer og teknologier, samt vejledning til hvordan vi bedst udnytter dem.

Vi var motiverede til at gøre vores proces efterlignelig, og har i den sammenhæng anerkendt betydningen af de forhold, samt muligheder vi har haft i løbet af processen - især de netværk, som vi har skabt vores viden igennem. I starten antog vi, at en postfænomenologisk videnskabsteoretisk tilgang, hvor vores fokus var på at undersøge, hvordan mennesker påvirkes af teknologi, ville være den bedste tilgang til at analysere den kunstige intelligens vi bruger. Løbene blev vi opmærksomme på, at vores samarbejde med vores netværks knudepunkter spillede en afgørende rolle, og influerede vores endelige tilgang, og vi endte derfor med at erkende betydningen af samarbejde og den kollaborative vinkel til vores projekt. Derfor valgte vi at undersøge, hvordan denne dimension påvirkede vores arbejdsproces. Vi indså, at vores ønske om at gøre vores proces efterlignelig og bidrage med brugbar viden til andre lignende opgaver, krævede en forståelse af hvordan vores viden blev genereret.

Vi blev introduceret til begrebet "Kollaboration" inden for vidensdannelse og blev enige om, at det var i tråd med vores open-source-proces og mål. Som et resultat besluttede vi os for at udforske betydningen af kollaboration og anti-disciplinær videnskab for vores arbejdsproces og vidensdannelse. Når man ønsker at skabe open-source machine learning, der tager udgangspunkt i en virkelighedsnær problemstilling, fandt vi at det er afgørende, hvilket netværk man opererer i. Vi valgte derfor at bruge kollaboration, der refererer til samarbejdet mellem forskellige aktører med forskellige baggrunde og ekspertise, til at løse komplekse problemer og udforske nye områder. Hermed har vi opnået ny viden, der ellers ikke ville være tilgængelig for os. Denne tilgang, der fremmer deling af viden, idéer og ressourcer, skaber et netværk, der med fordel kan inddrages i vores anskuelser om vigtigheden af netværket, fordi det giver redskaber til at forstå det. Projektet giver indsigt i hvordan lignende opgaver kunne løses, med overvejelser om hvordan netværket, hvori projektet er udarbejdet, spiller en essentiel rolle - hvilket giver andre problemløsere den viden der skal til, for selv at løse deres problem.

Problemfelt

Herpå vil der fokuseres på projektets kerne-pointe i problemformuleringen, samt relevante spørgsmål for projektet i form af arbejdsspørgsmål.

Problemformulering

Vores problemformulering sammendrager de tre primære aspekter af vores projekt, det tekniske og fysiske, som er vores udvikling af en Machine Learning model til at detektere og klassificere pollen, samt hvordan man kan digitalisere et mikroskop. Et andet aspekt er, at vores projekt har pådraget sig, som en del af dets formål, at være åbne og transparente i vores proces og beslutninger for at give viden videre til andre som står i en lignende situation. Og som følge af den open-source af process tilgang, behandler vi også vores projekts netværk og dens betydning for vores vidensbidrag, samt hvilken rolle samarbejde spiller for vidensbibraget. For at behandle disse aspekter vil vi gennem dette projekt forsøge at besvare følgende problemformulering:

“Hvilken betydning har et netværk der faciliterer samarbejde og vidensproduktion, for at udvikle en objektgenkendelses model til detektering og klassificering af pollen partikler, med det formål at udvise transparens og efterlignelighed i en open-source process?”

Arbejdsspørgsmål

I dette afsnit gennemgår vi de arbejdsspørgsmål som opgaven vil have fokus på, og som vi ønsker at besvare i løbet af projektet. Som led i at besvare problemformuleringen vil projektet besvare arbejdsspørgsmålene, enten for direkte at bidrage til at besvare den, eller for at give en bredere forståelse for projektet og hvad det senere vil konkludere. Derfor præsenteres alle arbejdsspørgsmålene nu, og derefter gives en grundig forklaring af hvorfor de har en indflydelse på vores projekt:

Arbejdsspørgsmål 1

“Hvad er baggrunden for vores projekt?”

Dette arbejdsspørgsmål har til formål at give overblik og redegøre for baggrundsinformation, som er nødvendige for at forstå vores projekt. Det uddyber også motivationsafsnittet. Her vil vores eksterne partnere beskrives, vores forhold til organisationen Astma-Allergi Danmark og deres pollen tælling, samt Fablab hvor vores udvikling af produkt har taget sted.

Arbejdsspørgsmål 2

“Hvordan skaber man en god projektstyring?”

I dette arbejdsspørgsmål vil der fokuseres på både den teoretiske og analyserende del af projektstyrings-processen igennem projektet. Der vil lægges vægt på SCRUM, kollaboration/kooperation og den agile udvikling. Under dette vil vi også gøre brug af, samt undersøge hvordan en iterativ proces har haft indvirkning i projektet, samt hvordan prototyper og iterationer af disse, har hjulpet os til en designløsning.

Arbejdsspørgsmål 3

“Hvad er objektgenkendelse, og hvordan har vi brugt YOLOv8 på digitalisering af mikroskop, til at detektere og klassificere pollen, vi selv har samlet?”

Dette spørgsmål besvares gennem en redegørende gennemgang af objektgenkendelse og dens relation til Artificial Intelligence og Machine Learning. Der beskrives en række forhold som spiller centrale roller for Machine Learning, såsom *Supervised* og *Unsupervised learning*, *Overfitting* og *underfitting* af en model, samt preprocessing og hvordan de begreber spiller ind i vores projekt. Derefter vil en gennemgang af vores produkt være nødvendig, for at skabe forståelse for hvordan vi gennem prototyper har løst opgaven, samt forklare gruppens relation til konstruktionen af vores egen model.

Arbejdsspørgsmål 4

“Hvor godt løser vores produkt sin opgave, og hvad bidrager det med?”

I dette arbejdsspørgsmål vil der både kritisk analyseres, samt evalueres hvor godt vores færdige produkt har været og hvordan det bidrager til ny viden under den nuværende proces for pollen-detektering og klassificering. Under dette vil der bruges trin-modellen til at give en forståelse af produktet, samt at analysere en teknisk og praktisk evaluering af produktet.

Arbejdsspørgsmål 5

“Hvilken betydning har vores netværk haft på vores projekt, og hvordan bruger vi det?”

Med dette arbejdsspørgsmål vil vi gerne undersøge hvordan et netværk har indflydelse på vidensdannelse, samt hvilken indflydelse som vores netværk har haft på vores designproces. Under dette vil vi inddrage teorier som, netværksteori, anti-disciplinær videnskab, 3XA, kollaboration og Kooperation der vil analyseres, samt diskuteres med formålet, at danne dyb forståelse for netværk og dens betydning. Både i vores projekt, og så for at give indblik i hvordan andre kunne foretage lignende projekter for at efterleve open source tilgangen. Endegyldigt leder vores udforskning af netværksteori til en bredere diskussion om videnskab, som vil berøres af *pollensamfundet*.

Afgrænsning

Som følge af projektets omfang er det nødvendigt for os at foretage en afgrænsning til specifikke emner, idet vi ønsker at undgå for mange pointer og sikre en skarp fokusering i vores projekt. Projektet sigter ikke mod at erstatte den nuværende proces, men snarere at udvikle et værktøj, der kan assistere den. Af samme grund drager projektet ikke konklusioner om, hvorvidt produktet kan erstatte medarbejdere, men i stedet søger det at undersøge mulighederne for kunstig intelligens på området.

Desuden er projektet en anti-disciplinær sammensmeltning af forskellige fagområder og forsøger derfor ikke udelukkende at besvare opgaven inden for datalogiens aspekt. Ikke desto mindre afgrænser projektet sig inden for de humanistisk-teknologiske rammer, og foretager en substantiel analyse af kunstig intelligens, men begrænser os samtidig med hensyn til dybdegående udforskning af dets kompleksitet. Samtidig tager projektet afstand fra Astma Allergi Danmarks konkrete arbejdsprocesser, da det ikke var muligt at opnå tilstrækkelig definition af dem til at inkludere dem præcist.

Redegørelse

Der vil efterfølgende blive redegjort for en række emner som er nødvendig for at få indblik i projektet. Dette er yderligere kontekst for vores motivation, samt en forklaring på de forhold vi har udarbejdet projektet under.

Problem Oprindelse

I dette afsnit vil der lægges vægt på hvor vores inspiration til problemstillingen fandt sted, her igennem at forklare om relevante aktører som bl.a. Astma-Allergi Danmark, FabLab, Humtek og de eksterne samarbejdspartnere, der har formet vores vidensgrundlag. Vi vil også have fokus på pollentyperne og hvordan de bliver indsamlet. Dette afsnit er derfor også med til at besvare arbejdsspørgsmål 1: “*Hvad er baggrunden for vores projekt?*”, hvorpå vi vil oplyse eksterne samarbejdspartnere, samt vores forhold til astma-allergi Danmark, pollen- tælling, og FabLab.

Astma-Allergi Danmark

Dette afsnit dækker over organisationen Astma-Allergi Danmark, og den arbejdsopgave som ligger centralt for vores problem.

Astma-Allergi Danmark er en dansk patientforening, der har til formål at forbedre livskvaliteten for personer med astma, allergi, eksem og høfeber i Danmark. Organisationens spiller en vigtig rolle inden for rådgivning, oplysning, og støtte. En af hovedopgaverne for Astma-Allergi Danmark er at indsamle og udgive pollental i Danmark. Yderligere tilbyder de vejledning om symptomer, behandlingsmuligheder, og forebyggelse. Ved at levere sådanne oplysninger hjælper organisationen med at øge forståelsen af astma og allergi, og give berørte personer værktøjer til at håndtere deres tilstande bedre (*Astma-Allergi Danmark, n.d.*).

En af de vigtigste opgaver de laver, er at indsamle pollen og tælle det for at få information om mængden af pollen i luften på et bestemt tidspunkt og på forskellige geografiske steder. Indsamlingen af pollen sker af Astma-Allergi Danmarks eget Pollenteam. I en video som Astma-Allergi Danmark har på deres hjemmeside, vises der på taget af Danmarks meteorologiske institut, hvor de omkring 15 meter over jorden har en af deres pollenfælder stående. Den fungerer lidt som en støvsuger, og drejer sig mod vindens retning. Pollenfælderne fanger pollen på plader, som derefter betragtes under et mikroskop af specialister. Dette er processen vi agter at forbedre.

Samlet set arbejder Astma-Allergi Danmark dedikeret på flere fronter, for at forbedre livet for personer med astma, allergi, eksem og høfeber. Gennem deres rådgivningstjenester, oplysningsarbejde og støttende fællesskab spiller de en afgørende rolle i at lette byrden for de berørte og fremme bedre forståelse og håndtering af disse tilstande i Danmark.

Pollentyper og indsamling

Følgende afsnit omhandler en beskrivelse af pollen ud fra følgende videnskabelige artikel:
Pollen trapping and storage (May 2012, Doug Somerville et. al)

Pollen er små korn, der indeholder mandlige reproduktive celler for planter. Disse korn spiller en vigtig rolle i pollinationen af blomstrende planter, og de kan også have en betydelig effekt på menneskers sundhed og miljøet.

Der er mange forskellige typer af pollen, og de kan klassificeres på flere måder. En måde at kategorisere pollen på, er ved at undersøge, hvilke typer planter de kommer fra. Nogle af de mest almindelige pollen kilder er træer, græs og urter. Træpollen er ofte en stor kilde til allergener om foråret, mens græs- og urtepollen kan være mere udbredt om sommeren. Pollen kan også klassificeres efter formen af deres korn. Enkelte pollenkorn kan være runde, ovale, trekantede eller stjerneformede.

For at indsamle pollen kan man bruge en række forskellige teknikker afhængigt af det ønskede formål. En simpel metode til at indsamle pollen er at placere en prøvebeholder under en plante og ryste den let for at løsne pollenkornene. Prøvebeholderen kan derefter transporteres til et laboratorium til yderligere analyse. En mere systematisk tilgang er at

installere et pollenfælde, som normalt består af en luftstrøm, der er rettet mod en overflade belagt med klæbende materiale. Luftstrømmen samler pollen-kornene, mens de passerer gennem fælden, og klæbematerialet fastgør dem til overfladen. Fælden kan placeres på en høj bygning for at indsamle pollen fra forskellige planter i området, og resultaterne kan bruges til at overvåge pollen-niveauer og identificere allergifremkaldende planter i området.

I laboratoriet kan pollen analyseres ved hjælp af mikroskopi og molekylærbiologiske teknikker. Identifikation af pollentyper kan hjælpe med at forstå deres indvirkning på menneskers sundhed og miljøet og kan også bruges til at udvikle strategier til at minimere deres negative påvirkning.

Hver dag i pollensæsonen bliver der udgivet dagens pollental, som er en indikator for, hvor mange pollen-partikler der er registreret i en kubikmeter luft i det foregående døgn. Pollen bliver målt i København og Viborg og kan findes inde på DMI's hjemmeside (*DMI, n.d.*).

FabLab

Dette afsnit vil beskrive det fysiske sted og konteksten hvori vores projekt er blevet udviklet. Det er inkluderet fordi det har relevans for de netværk vi agerer i, samt for den anti-disciplinære tilgang som vi kommer til at pådrage os selv, og som vil blive forklaret senere i rapporten. Fablab har haft stor betydning for vores arbejdsproces og for projektets ideologi. Der vil senere blive uddybet, hvordan Fablab har været en del af projektets netværk.

I projektet er der blevet gjort brug af et af Roskilde Universitets (RUC) faciliteter; Fablab - der gennem projektet har været en stor hjælp til at fuldføre vores mål. FabLab RUC er et rapid prototyping laboratorie, samt en digital produktions workshop, hvor alle studerende på Roskilde Universitet er velkommen til at gøre brug af deres redskaber, maskiner og ressourcer (*FabLab, n.d.*). Under dette kan FabLab håndtere materialer som træ, plast, metal, tekstiler, elektronik programmering og computer kontrolleret fremstilling (*FabLab, n.d.*). FabLab som et eksperimentelt, kreativt lærings- og forsknings fakultet, stiller

hermed banebrydende værktøjer til rådighed for at kunne opnå denne rapid prototyping. FabLab har en tradition som stammer fra hackerspacet, hvorpå man selv får sit produkt i hænderne og ikke nødvendigvis arbejder efter traditionelle metoder/modeller for at opnå sit design. Det var også igennem vidensgrundlaget fra FabLab, at projektets problemfelt tog form, herigennem design og samtaler med ansatte. FabLab spiller en stor rolle for projektet, da FabLab interagerer og sammenfletter forskellige fagområder med hinanden på Roskilde Universitet, hvor disse fagområder normalt kan være meget indelukkede og beskyttende overfor samarbejde. Med dette menes der at FabLab kan bruges som et samlested for forskellige fagområder, hvorpå projekter, prototyper og produkter kan fremstilles under hvilket som helst fagområde.

Projektet er også tildelt en teknisk vejleder fra Fablab, Bo Thorning, som har ageret som mentor for projektets tekniske udvikling og som bindeled til faglig viden uden for vores projektgruppes ekspertise.

HumTek

Dette afsnit giver kontekst for de faglige krav som projektet er underlagt, men mere centralt den faglige tradition bag HumTek.

HumTek er en forkortelse for Humanistisk-Teknologisk Bacheloruddannelse. Det er en tværfaglig uddannelsesretning, der kombinerer fagområderne humaniora og teknologi. Uddannelsen fokuserer på at integrere humanistiske og teknologiske perspektiver for at takle komplekse samfundsudfordringer og udvikle innovative løsninger.

Som en tværfaglig uddannelse kombinerer HumTek elementer fra humanistiske fag såsom sprog, kultur, filosofi og samfundsvidenskab med tekniske fag som datalogi, informatik, matematik og naturvidenskab. Formålet med HumTek er at skabe en bred og alsidig uddannelse, der giver de studerende mulighed for at udvikle en dybdegående forståelse af både humanistiske og teknologiske perspektiver. Uddannelsen sigter mod at uddanne studerende, der kan forstå og håndtere komplekse problemstillinger ved at integrere viden og metoder fra både humaniora og teknologi (*Roskilde University, n.d.*).

En vigtig del inden for HumTek er problemorienteret projektlæring (PPL), som er Roskilde Universitets pædagogiske model, der bygger på syv principper: Projektarbejde, problemorientering, tværfaglighed, deltagerstyring, gruppearbejde, eksemplaritet, internationalt blik og udsyn. PPL er primært knyttet til projektarbejde, men har også relevans i kursusundervisning. På uddannelsen er de studerende centrale aktører i PPL, hvor de udvikler og formulerer relevante problemer og undersøger dem ved at anvende deres viden fra kurserne. Gennem projektarbejdet arbejder studerende med problematikken over længere tid og opnår dermed en dybere og mere kompleks forståelse. Dette giver mulighed for at opbygge vigtige kompetencer i forhold til at indgå i og styre længerevarende undersøgelser (*Roskilde University, n.d.*).

Eksterne samarbejdspartnere

Følgende er en gennemgang af vores eksterne samarbejdspartnere, aktører som har haft betydning for dets udvikling men som ikke er en del af projektgruppen. Dette vil senere bruges til at danne forståelse for projektgruppens netværk og hvad det har bidraget til. Forståelse for aktører som har spillet roller i vores projekt er nødvendig for læsning af vores analyse af vores netværk. Det er skrevet på baggrund af korrespondance mellem projektgruppen og aktører der bliver omtalt.

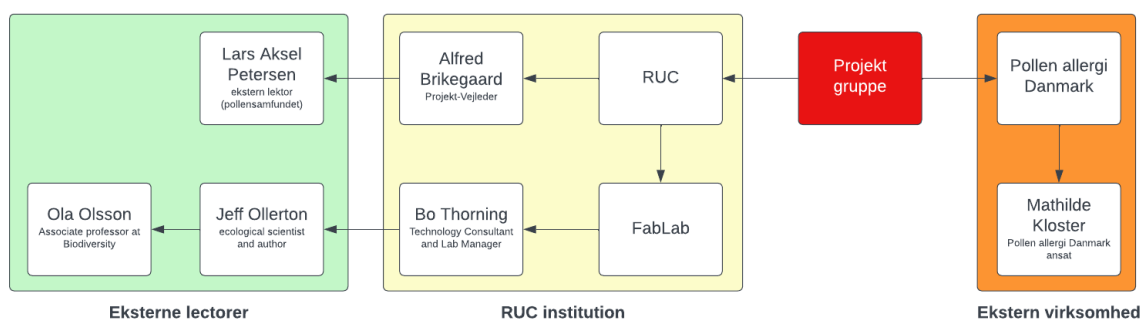


Fig 1. En beskrivelse af det netværk vi har skabt, og hvordan forbindelserne er opstået.

Bo Thorning

Efter at have hørt et projekt fra Bo Thorning omkring brugen af AI til at identificere bakterier i vand via billeder, søgte vi hjælp og vejledning af ham, da vores projekter minder om hinanden. Bo Thorning har en baggrund inden for teknologi og innovation. Han arbejder og underviser på Roskilde Universitet i FabLab, hvor han blandt andet lærer de studerende hvordan maskinerne i 2D og 3D fungerer. Han har været industritekniker i Danfoss, og har arbejdet aktivt med lys og lyd inden for scenebranchen. Han har blandt andet bygget mikroskoper med AI-vision, og laser projection systems, og har dertil en bred viden om rapid prototyping, Machine learning, og Artificial intelligence.

Bo henviste os yderligere til en af de andre aktører; Jeff Ollerton, da han mente han også kunne give noget viden og indsigt til vores projekt.

Jeff Ollerton

Jeff Ollerton er ekstern lektor i instituttet for naturvidenskab og miljø. Vi blev henvendt til at tage kontakt med ham, fordi han allerede havde lavet arbejde med pollen før, og kunne derfor rette os imod hvordan vi selv skulle lave vores forarbejde med pollenkor. I løbet af en karriere, der strækker sig over mere end 30 år, har han etableret sig som en af verdens førende eksperter inden for pollen- og pollen-bestøvning. Han er forfatter til mere end 150 artikler og bogkapitler, hans ofte citerede, banebrydende forskning blevet anvendt af nationale og internationale instanser. Jeff er også efterspurgt som rådgiver og konsulent for regeringer, lokale myndigheder, trykte og elektroniske medier samt finansielle organisationer. Jeffs bidrag til projektet var igennem gode vinkler og teknikker til hvordan vi kan komme videre med vores egen pollenanalyser (*Ollerton, n.d.*).

Alfred Birkegaard

Alfred Birkegaard har været vores vejleder igennem projektet. Han har en to-laget karriere som akademiker og entreprenør. Han har en Ph.d., MA, og BA i filosofi og fysik fra Roskilde Universitet. Han grundlagde Open Media Lab på RUC, og også medstifter af Thirdroom, som en studenterforsknings platform. Alfred hjalp projektet med den humanistiske vinkel, og pegede os i retning af relevante netværksteorier.

Astma Allergi Danmark

Vi nævner Astma Allergi Danmark i dette afsnit, fordi at vi ikke var i stand til at opføre et samarbejde med dem, men grundet at de har været en relevant aktør i projektet, har vi valgt at inddrage dem alligevel. Projektet søger at undersøge hvilken rolle Astma Allergi Danmark har haft på vores netværk og vidensdannelse. Selvom Astma Allergi Danmark desværre takkede nej til et samarbejde, mener vi stadig, at vores idé om en teknologisk løsning kunne have været gavnlig for deres arbejde med at identificere og indsamle pollen arter.

Ola Olsson

Ola Olsson er en associeret professor inden for biodiversitet på Lund Universitet. Han kombinerer modellering og empiriske metoder for at løse videnskabelige problemer inden for bevaringsbiologi. Ola var relevant for vores projekt, da han allerede havde forsøgt et projekt lignende til vores, som vi kunne bruge til inspiration. Vi har dog ikke samarbejdet med Ola som ønsket, da det ikke var muligt at holde kontakten med ham.

Teori

I dette afsnit præsenterer vi den grundlæggende teori, der danner rammerne for vores projekt. Vi vil fokusere på vigtige tekniske teorier, der er relevante for vores projekt og danner grundlaget for udarbejdelsen af både opgave og fysisk produkt.

Open Source

Vores vinkling på projektet er påvirket af, og forsøger at efterleve en Open source tilgang. Denne tilgang beskrives i følgende afsnit og kan ses løbende i vores projekt. Vores problemstilling inkluderer begrebet og tilgangen har indflydelse på vores senere valg af analyse og diskussionspunkter. Afsnittet fungerer som baggrundsviden og kontekst, og vores bidrag gennem open source diskuteres.

Open source henviser til den tilgang at data, software og projekter bliver gjort frit tilgængeligt for offentligheden, og bygger på konceptet om fri deling af viden. Ofte bliver disse projekter gjort tilgængelige for offentligheden, for at skabe muligheden for at opnå nye resultater - altså en videre bygelse på det offentliggjorte materiale eller viden, i håb om at opnå bedre resultater. Vores projekt inddrager dette i en mere bred sammenhæng, hvor vi vil gennemgå så meget af vores projekt og produkts udvikling, med det formål at den vidensdannelse senere kan bruges af andre i deres projekter.

Open source fungerer på princippet om kollektiv indsats, og dannelse af ny viden sker på baggrund af mange deltageres bidrag. På trods af open source gode kvaliteter, bliver det vigtigt at nævne licensering. Der er forskellige open source-licenser, der fastlægger betingelserne for brug, ændring og distribution af softwaren. Nogle af de mest kendte licenser inkluderer GNU General Public License (GPL), Apache License og MIT License. Disse licenser sikrer, at softwaren forbliver åben og frit tilgængelig for alle, samtidig med at de beskytter udviklernes rettigheder og fremmer fortsat deltagelse og videreudvikling. Projektet har eksempelvis gjort brug af Ultralytics YoloV8 AI, der er open source, men YoloV8 muliggør brugen af andre open source teknologier, som f.eks; ClearML, PyTorch, OpenCV mm. Vi har blandt andet udnyttet PyTorch til at træne og køre vores model -

hvilket giver en ide om, hvordan open source projekter bygger oven på hinanden, og hvordan de konstant forsøger at demokratisere udviklingen og skabe forbedringer. Den frie deling af viden samt tilgængelighed for offentligheden er centralt for vores tilvalg af denne tilgang.

Vores tilgang til open source, hvor processen og resultater bliver fremvist med det forhold at tillade videre udvikling, kan sættes i en Citizen Science kontekst. Citizen Science er defineret på mange forskellige måder, men vores open source tilgang kan tillægges "Citizen Science – the participation of the general public in scientific processes... an open and inclusive approach, for example, by supporting and being part of the exploration, shaping, and development of the different aspects of the citizen science movement, its better understanding, and use for the benefit of decision-making" af European Citizen Science Association (Vohlan. K et al., 2021). Vores open source tilgang er en måde at facilitere Citizen Science.

Projektstyring

I dette afsnit vil vi gå i dybden med de teorier, der har været vigtig for vores projektstyring. Under dette bruger vi projektstyrings softwaren Jira, til at facilitere SCRUM metoden, der har været nyttig i arbejdsprocessen. Til sidst forklares den iterative-designproces som begreb, hvilket leder til hvordan prototyper kan hjælpe et projekt med at komme i mål. Afsnittet forsøger at svare på arbejdsspørgsmål 2: "*Hvordan skaber man en god projektstyring?*", ved at redegøre metoder som kan facilitere projektstyring. Spørgsmålet vil videre behandles i SCRUM analysen af vores konkrete projekt.

Scrum

Dette afsnit beskriver SCRUM metoden som vi har brugt til at holde vores deadlines, og styre projektets udvikling.

Scrum er baseret på den agile tankegang, der fokuserer på en iterativ tilgang, hvor processen gentages regelmæssigt. Denne metode anvendes primært til projektledelse og hjælper teams med at organisere og styre deres arbejde. Scrum promoverer læring gennem erfaring, selvorganisering mens man arbejder med et problem, og refleksion over sejre og nederlag for at opnå en forbedring kontinuerligt (*Mannaz, n.d.*).

Scrum er ofte associeret med softwareudvikling. Men dens principper og læringsmetoder kan anvendes på andre områder, hvilket er en af grundene til dens popularitet. Scrum beskriver en række møder, værktøjer og roller, der arbejder sammen for at hjælpe teams med at strukturere og styre deres arbejde. De grupper, der anvender Scrum-metoden, betegnes som "*Scrum-teams*". Et Scrum-team er et tværfagligt team, som typisk består af 1-10 personer, men alligevel er i stand til at fuldføre et godt stykke arbejde inden for en given "*Sprint*"-periode i mellem en til tre uger. Scrum-teams er kendt for deres evne til at reagere hurtigt på ændringer i krav og prioriteter. (*Drumond, n.d.*).

Scrum-teams består af tre overordnede roller: "*Produkt Ejer*", "*Scrum Master*" og "*Scrum-teamet*". Produkt Ejer(ne) er den/de person(er), der ejer produktet på vegne af virksomheden, og selvom de ikke er chefen over de andre, er de en vigtig del af teamet.

Scrum Masterens hovedansvar er at implementere Scrum-metoden i deres team. Selvom det i dag er blevet en mere ledelsesorienteret rolle, blev den oprindeligt designet til at have en person i teamet, der havde god forståelse for Scrum-metoden og kunne guide teamet, produkt-ejeren(e) og forretningen gennem processen. I denne rolle planlægger Scrum Masteren de nødvendige ressourcer til aktiviteter, som f.eks Sprint-planlægning og er ansvarlig for at forbedre samarbejdet mellem teamet og forretningen (*Visual Paradigm, n.d.*).

Scrum-teamet har som hovedopgave at være dygtige i at gennemføre projekter. De bedste Scrum-teams er tæt knyttede og arbejder typisk sammen på samme sted. Hvert medlem af

teamet bidrager med forskellige færdigheder. Scrum-teams er selvorganiserede og har en fælles "vi-tilgang", hvilket betyder, at alle medlemmer bidrager til at sikre en vellykket afslutning af Sprintet, som teamet er i gang med. Scrum-teamet planlægger og driver planen for hvert Sprint og forudsiger, hvor meget arbejde de tror, de kan gennemføre i løbet af iterationen. Efter hvert Sprint får Scrum-teamet feedback, som hjælper dem med at forbedre sig over tid (*Drumond, n.d.*).

Scrum-frameworket omfatter en række planlagte begivenheder og møder, som Scrum-teams udfører regelmæssigt for at sikre en struktureret og koordineret tilgang til deres projekter. Det er op til hvert enkelt team at vurdere, om disse begivenheder er nødvendige for deres arbejdsproces eller om de skal tilpasses til at imødekomme deres specifikke behov og præferencer. Nogle af de vigtigste begivenheder inkluderer "*Sprint Planning*", og "*Daily Scrum*".

"Sprint planning", er et møde hvor hele udviklingsteamet planlægger arbejdet, der skal udføres i den kommende sprint periode. Under mødet fastlægger Scrum masteren sprint-målet, og teamet diskuterer og udvælger de opgaver, der skal løses for at nå målet. Dette er en af de vigtigste events i Scrum, da det sikrer, at teamet har en fælles forståelse af deres mål og arbejdsopgaver.

Et "Sprint" er en fast periode, typisk på én til tre uger, hvor Scrum-teamet fokuserer på at løse en udvalgt gruppe af opgaver fra "Product Backlog" og levere en fungerende version af produktet ved sprintets afslutning.

"Daily Scrum" er et dagligt møde, som varer omkring 20 minutter og holdes på samme tid hver dag. Mødet har til formål at sikre, at hele teamet er opdateret om, hvad der skal laves, og planlægge, hvad der skal ske i løbet af de næste 24 timer. Mødet holdes typisk om morgenen, så hele teamet kan være til stede (*Drumond, n.d.*).

Jira

Dette afsnit forklarer softwaren Jira og hvordan det kan facilitere en Scrum process.

JIRA er en projektstyringssoftware udviklet af det australske firma Atlassian. Softwaren er baseret på den agile metode, og JIRA anvendes til forskellige formål, herunder fejlrettelse, problemovervågning og projektledelse. JIRA-dashboardet tilbyder flere nyttige funktioner og muligheder, der gør det nemt at håndtere problemer og opgaver.

En af JIRA's primære fordele er det brede udvalg af værktøjer, der kan anvendes til forskellige opgaver. For eksempel gør JIRA det nemt at oprette og håndtere opgaver ved hjælp af funktioner som påmindelser og deadlines. Desuden hjælper JIRA med at designe detaljerede roadmaps for projekter og faciliterer uddelegering af opgaver, deling af planer og overvågning af fremskridt. Dette sikrer, at projektets proces og status altid er synlig, og det er muligt at evaluere, hvor langt man er nået i projektet. Endvidere understøtter JIRA også agile teams ved at tilbyde Scrum- og Kanban-boards til hold, der arbejder efter agile metoder(*Simplelearn, 2022*).

Iterativ process

Dette afsnit forklarer den iterative designprocess, hvordan den fungerer og hvilke fordele den har, i forhold til en mere forud-planlagt udviklingsproces.

Den iterative designproces er beskrevet som den moderne eller agile fremgangsmåde, der skal forsøge at erstatte den gamle vandfaldsmodel. (*Basili & Larman, 2003*). Processen er en tilgang til løbende at forbedre et koncept, design eller produkt (*Eby, 2019*). Et af nøgleelementerne er, at når man har lavet et iterativt design, tester man det med det samme. Det vil sige at design processen involverer en cyklus af rapid prototyping, og tests af et produkt. Rapid prototyping er, når man udvikler prototyper hurtigt og løbende opsummere på dem, samt viderebringer den viden som følger, i næste prototype. Hver cyklus producerer et udviklet segment, der danner grundlaget for den næste cyklus med iterativ forbedring (*Eby, 2019*). Dette kan medføre at produktiviteten bliver bedre, og dermed også sandsynligheden for brugernes behov bliver opfyldt. Processen forudsætter, at svarene ikke allerede eksisterer, eller at man ikke kender det miljø som produktet skal være i, såvel som

hvordan kundernes behov vil ændre sig i løbet af udviklingen. En iterativ proces tager højde for et skiftende miljø, og giver en mulighed for at planlægge ændringer, mens man skaber sit produkt, og hjælper med at producere leveringer, der er skræddersyet til det marked som produktet skal ud i (*Rajput, 2023*).

Prototyping

Afsnittet forklarer prototyping som et begreb, det falder i med den iterative design process. Vi bruger prototyping til vores produktudvikling.

Prototyping er en fundamental metode inden for udvikling og design og kan anvendes på tværs af forskellige fagområder, som f.eks. produktudvikling, softwareudvikling og innovation. Prototyping-teorien stammer fra Eleanor Rosch og blev udviklet i 1973 under den kognitive videnskab (*Oxford Reference, n.d*). Formålet ved prototyping er at skabe foreløbige versioner eller modeller af et ønsket produkt, idé eller system designeren gerne vil udvikle. Prototyping gør det muligt at lave en testversion af det endelige produkt, hvorpå kostelige materialer eller et flot design ikke er nødvendig, da man som regel tester mindre elementer af designet igennem (*Johnson, 2023*). Herpå ses det typisk at prototyper kommer igennem iterationer, hvor man typisk ser designet udvikle sig eller tage forskellige retninger som er præget af det vidensgrundlag som man opbygger på vejen. Ved hjælp af prototyping kan man derfor teste og/eller evaluere designets funktionalitet, design eller gennemførsel. Den iterative natur af prototyping giver hermed designeren/udvikleren mulighed for at samle værdifuldt feedback, forbedre eller forfine deres ideer til det endelige produkt eller løsning.

Teknisk teori

Machine Learning

Følgende afsnit dækker begrebet Machine Learning, og dets relation til Artificial Intelligence begrebet. Den grundlæggende forståelse for Machine Learning vil derefter danne rammer for den specifikke teknologi og objektgenkendelse, vi vil benytte. Dette afsnit vil forsøge at besvar første del af arbejds spørgsmål 3: *“Hvad er objektgenkendelse, og hvordan har vi brugt YOLOv8 på digitalisering af mikroskop, til at detektere og klassificere pollen, vi selv har samlet?”*.

AI står for Artificial Intelligence (Kunstig Intelligens). Det henviser til teknologier og systemer, der er designet til at efterligne menneskelig intelligens og tænkning. AI omfatter en bred vifte af metoder, tilgange og teknikker, der sigter mod at give computere mulighed for at udføre opgaver, der normalt kræver menneskelig intelligens (Skytt, L, 2023).

Machine learning er en gren inden for kunstig intelligens og datalogi, der fokuserer på brugen af data og algoritmer til at imitere den måde, computermødelles lærer på og gradvist forbedre præcisionen. Machine learning algoritmer bruger data som input til at forudsige nye output værdier, og formålet med machine learning er at gøre software applikationer mere præcise til at forudsige resultater uden at være eksPLICIT programmeret til dette. Disse forudsigelser kan opnås ved at træne machine learning modellen på input data som kan være labeled eller unlabeled data, derefter kommer algoritmen med output data (IBM. (n.d.) *What is machine learning?*). Labeled og unlabeled data vil blive uddybet i afsnittet om supervised og unsupervised learning. For eksempel bruger Uber algoritmer til at matche chauffører med passagerer, og Google bruger machine learning til at præsentere annoncer omkring køreture i søgninger (Burns, E, 2021). Der findes forskellige typer inden for machine learning. Disse typer er supervised learning og unsupervised learning, og der vil blive forklaret i næste afsnit.

Supervised vs unsupervised learning

Dette afsnit søger at forklare AI, og underkategorien af AI; machine learning, de to primære måder at lave machine learning på.

For at forstå hvordan AI fungerer så skal vi tage et kig på to essentielle dele inden for AI som er Machine learning og Deep learning. Ethvert AI-system, der fungerer, indeholder en eller flere af disse metoder for AI-udvikling. Machine learning er *"Når computere lærer fra data ved hjælp af algoritmer til at udføre en opgave uden at være eksplicit programmeret."* (Wolfewicz, 2023). Deep learning *"beskriver teknologien, hvor algoritmer analyserer data med en logisk struktur, der ligner, hvordan en menneskelig person ville drage konklusioner."* (Wolfewicz, 2023)

Machine learning kan opnås ved at udvikle en algoritme, hvorefter maskinen kan lære ud fra denne specifikke algoritme. Disse algoritmer kan bruges til at udføre en opgave uden at skulle programmeres til at udføre den. I stedet er det baseret på forudsigelser, hvilket betyder, at algoritmen genkender mønstre i dataene og laver forudsigelser, når der kommer nye data.

Der eksisterer to hovedtyper af maskinlæring: supervised og unsupervised learning. Supervised learning anvender en kendt sammenhæng mellem input og output. Målet med supervised learning er, at algoritmen lærer fra "korrekte svar" eller det, der ofte omtales som "labeled data". Disse data bruges til at træne algoritmen, og den anvender den indsamlede viden til at foretage forudsigelser, når nye input data præsenteres (Wolfewicz, 2022).

Unsupervised learning er det modsatte af supervised learning, og Unsupervised learning kræver kun input data eller *Unlabeled data*. Vi kan bruge denne metode, når vi har at gøre med problemer, hvor vi ikke ved, hvordan resultaterne skal se ud, og formålet med Unsupervised learning er at opnå viden (Wolfewicz, 2022).

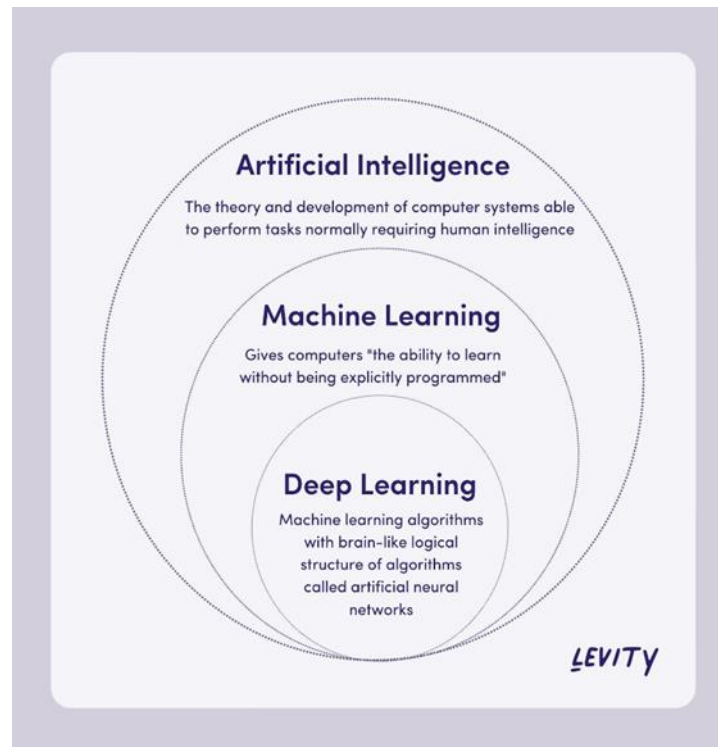


Fig 1. Figur over AI, machine learning og deep learning (Wolfewicz, 2023)

På billedet kan vi se dele af AI. Billedet viser, at Machine learning er en del af kunstig intelligens, og Deep learning er en kompleks del af Machine learning.

Deep learning er den komplekse version af Machine learning, fordi vi skal udføre nogle komplicerede matematiske ligninger for at opnå en god dyb lære-algoritme. Deep learning kan føre til resultater, vi ikke havde troet var mulige. Deep learning fungerer på en måde, der ligner, hvordan menneskets hjerne fungerer. Den tager nogle data og analyserer dem logisk, præcis som den menneskelige hjerne gør. For at opnå dette mål anvender deep learning en stratificeret, det vil sige en opdeling i mindre dele, arkitektur af algoritmer, kendt som et kunstigt neuralt netværk (ANN). Designet af ANN er inspireret af den menneskelige hjerne, hvilket kan resultere i en mere effektiv læringsproces end de standard machine learning modeller. (Wolfewicz, 2023).




Fig 3. Figur over et eksempel på et neuralt netværk (Wolfewicz, 2023)

I ovenstående billede ses et eksempel på et simpelt kunstigt neuralt netværk (ANN), og vi kan observere, at venstre lag kaldes input-laget, mens højre lag kaldes output-laget. I midten ser vi flere lag kaldet skjulte lag. Disse skjulte lag udgør beregnede værdier, der kan anvendes af netværket. Ethvert ANN med mere end to skjulte lag betragtes som et dybdegående (Deep learning) netværk (Wolfewicz, 2023).

Objektgenkendelse & YOLOv8

Dette afsnit dækker den mere specifikke teknologi, inden for Machine Learning, Objektgenkendelse. Den beskriver også den specifikke type af objektgenkendelse som vi har brugt: YOLOv8.

Objektgenkendelse er en data visualiseringsmetode, som indeholder både klassifikation, identifikation af hvad et objekt er, og detektering, lokaliseringen af objekter på både billeder og video. Objektgenkendelse bliver brugt i flere sammenhænge i hverdagen, i alt fra selvkørende biler til overvågningskameraer. Objektgenkendelse algoritmer er opdelt i to kategorier; *single-shot detectors* og *two-stage detectors* (Kundu, 2023). Single-shot genkendelse gør brug af en enkelt gennemgang af input-billedet, der gør at den kan komme med forudsigelser om hvad billedet indeholder, ud fra de bounding boxes brugeren har sat

op. Single-shot behandler billederne på en enkelt gennemgang, hvilket gør single-shot tidsmæssigt effektiv. Generelt så er single-shot genkendelse mindre præcis end andre metoder og den er ikke særlig effektiv til at detektere små objekter på billeder, men den er stadig brugbar og kan bruges til specifikke opgaver (Kundu, 2023).

Two-shot genkendelse benytter to gennemgange af input-billedet til at komme med forudsigelser, den første gennemgang bliver brugt til at generere mulige objekt lokationer, og her forudsiger modellen selv hvilke dele af billedet der er relevante, hvor den anden gennemgang bliver brugt til at forfine disse forslag og komme med endelige forudsigelser. Disse mulige lokationer bliver skabt gennem en proces der hedder Region Proposal Network, som er en algoritme der først analyserer billedet ud fra de eksisterende bounding boxes, og herefter skærer unødvendige dele fra, for at give en mere præcis model, når den kommer med sine endelige forslag på hvad billederne indeholder.

Two-shot genkendelse er ofte mere præcis end single-shot, men den kræver flere computer kræfter. Generelt set er single-shot bedre til real-time applikationer hvor two-shot er bedre når nøjagtighed er vigtigere (Kundu, 2023).

Yolo (You Only Look Once) er en single-shot objektgenkendelse algoritme som benytter end-to-end neural network til at lave forudsigelser af ” bounding boxes og class probabilities” på samme tid. En måde at bestemme placeringen af et objekt i et billede er, at Bounding boxes, i sin simpelhed, er firkanter på et billede, hvor koordinaterne bliver gemt.

Yolo implementere ikke RPN (Region Proposal Network), men er bundet til brugerens præ-definerede bounding boxes, og opdeler derfor ikke selv billedet i regioner, der ville kunne øge præcisionen af modellen - Yolo gør op for dette ved at være hurtigere og mindre krævende i forhold til den processerings kræft den kræver (Kundu, 2023).



Fig 4: Billede af pollen i en Bounding Box. Boxen er her rød og ovenover står klassifikationen af objektet i Bounding Boxen: "Pollen-Birch", samt hvor sikker den er på sin klassificering. Billedet er resultatet af vores egen model, på egne billeder.

Overfitting og underfitting

Dette afsnit vil gennemgå begreberne underfitting og overfitting og deres relevans for vores projekt. Begge begreber beskriver problemer, der kan opstå i forbindelse med en machine learning-algoritme, når den er trænet på data, der ikke er tilstrækkelige til at opnå en model, der kan løse opgaven eller opfylde målet.

Underfitting benyttes til at beskrive modeller, hvor datasættet ikke rækker, og modellen er ude af stand til at finde underliggende trends, regler eller mønstre, når den bruges på nye data. Dette skyldes oftest, at datasættet er for småt eller for specifikt. Hvis et datasæt ikke indeholder nok kategorier eller forskellige datapunkter, bliver modellen ufleksibel, hvilket betyder, at den ikke kan bruges til bredere forudsigelser. I dette tilfælde kan en machine learning-model beskrives som “underfitting”.

Geeksforgeeks.org forklarer følgende grunde til underfitting af data (*dewangNautiyal, 2023*)

- Høj bias og lav variance
- Størrelsen af træningssættet er ikke tilstrækkelig.
- Modellen er for simpel.
- Træningsdata er ikke rensede og indeholder også støj i det.

Overfitting kan anses som modsætningen til underfitting og opstår, når der er for meget data. Overfitting beskriver en model, der ikke kan lave forudsigelser på grund af for bred data. Hvis modellen begynder at gå for meget i detaljer, kan det betyde, at den ikke kan se ligheder mellem forskellige data, som ellers ville have været kategoriseret sammen.

Geeksforgeeks.org forklarer følgende grunde til overfitting af data:

- Høj variance og lav bias
- Modellen er for kompleks
- Størrelsen af træningsdata

For at uddybe og sikre forståelse af begreberne vil der her inddrages et eksempel. Forestil en machine learning-model med formålet at identificere træblade på billeder. Hvis modellen har et passende fit, vil den kunne forudsige, om et blad optræder på billedet.

En underfit-model er ude af stand til at identificere alle blade, fordi datasættet måske indeholder blade, der ikke er grønne. Det kan resultere i, at et brunt blad ikke bliver identificeret, eller at modellen identificerer et objekt, som ikke er et blad, ved falsk positiv, blot på grund af objektets grønne farve.

En overfit-model kan f.eks. ikke anse et løvblad for at være et træblad, fordi træningssættet indeholder alt for mange bøgeblade, og derfor bedømmer, at løvbladets form ikke gør det til et træblad. Eller den kunne være trænet på billeder taget med et bestemt kamera og afvise alle blade, som ikke har samme digitale artefakter. En overfit model husker bestemte billeder i stedet for at lave regler.

At forstå begreberne underfitting og overfitting har relevans for vores projekt, da vi vil bruge machine learning til at løse vores problemformulering. Hvis modellen er underfittet, vil den ikke kunne finde de rigtige sammenhænge og sammenligninger i datasættet, og dermed vil dens præcision falde. Omvendt vil en overfit model give en høj præcision på træningsdata, men den vil ikke kunne generalisere og præcisere lige så godt på ny data, som den ikke er blevet trænet på.

Data preprocessing

Dette afsnit forklarer, hvordan vi har behandlet vores datasæt. Dette involverer brug af Roboflow til at konvertere et anoteringsformatet. I vores egen model er det brug af Roboflow til at annotere vores egne billeder. Derudover gennemgår vi opdeling af datasæt i træning og test split. Afsnittet beskriver de aspekter af data preprocessing som er relevante for vores projekt, men begrebet omfatter mange yderlige processer.

Data preprocessing er en vigtig fase i machine learning, hvor data bliver manipuleret og transformeret for at gøre dem brugbare til træning af machine learning modeller. Dette omfatter blandt andet "rengøring" af indsamlede data, for at rette eventuelle fejl eller manglede datapunkter som der kan opstå, eller integrering af data fra forskellige kilder (*Javatpoint, n.d.*).

En essentiel del af data preprocessing af supervised learning er annotering. Dette er hvor metadata eller etiketter bliver tilføjet til dataene. Annotering er nødvendig i supervised

learning, hvor et træningssæt kræver etiketterede eksempler for at træne modellen til at genkende mønstre. Ved at tilføje relevante etiketter eller metadata kan annotering bruges til at bygge og forbedre modellens evne til at generalisere og træffe præcise forudsigelser (*Roboflow, 2022*) (*Roboflow, 2023*)

Når datasættet er forberedt, er det vigtigt at opdele det korrekt i træning, validering og test. Træning er den del af datasættet som bliver brugt indledende af machine learning modellen til at sætte regler, generaliseringer og generelt bygge den. Validerings-sættet bruges, når træningen er overstået. Den trænede model bruges på validerings-sættet og resultaterne bliver evalueret, den evaluering appliceres så på modellen gennem tuning af parametre i den. (*Brownlee, 2017*). Når modellen er trænet og valideret, er den færdig. Test-sættet bruges så til at vurdere hvor effektiv modellen er.

En typisk praksis er at bruge en 80-10-10-opdeling, hvor 80% af dataene bruges til træning af modellen, 10% til validering af modellens præstation under træningen, og de resterende 10% til test for at evaluere den endelige ydeevne af modellen på ukendte data (*Agrawal, 2021*). Ved at følge denne proces, der involverer data preprocessering, annotering og korrekt opdeling af datasættet, kan man forberede dataene optimalt til machine learning og sikre, at modellen trænes og evalueres på en pålidelig og objektiv måde (*Agrawal, 2021*).

Roboflow

Roboflow er et værktøj der gør det muligt for brugere at træne deres computer vision modeller som er en machine learning model (*Microsoft Azure, n.d.*), uden at skulle have en dybdegående viden om programmering eller machine learning. Roboflow understøtter en række forskellige metoder for at hjælpe brugere med at forbedre deres computer vision modeller hurtigt uden at man skal bruge flere timer på det (*Roboflow, 2023*).

Roboflow består allerede af publicerede datasæt, der er klar til brug for brugere (*Bhattacharyya, 2020*).

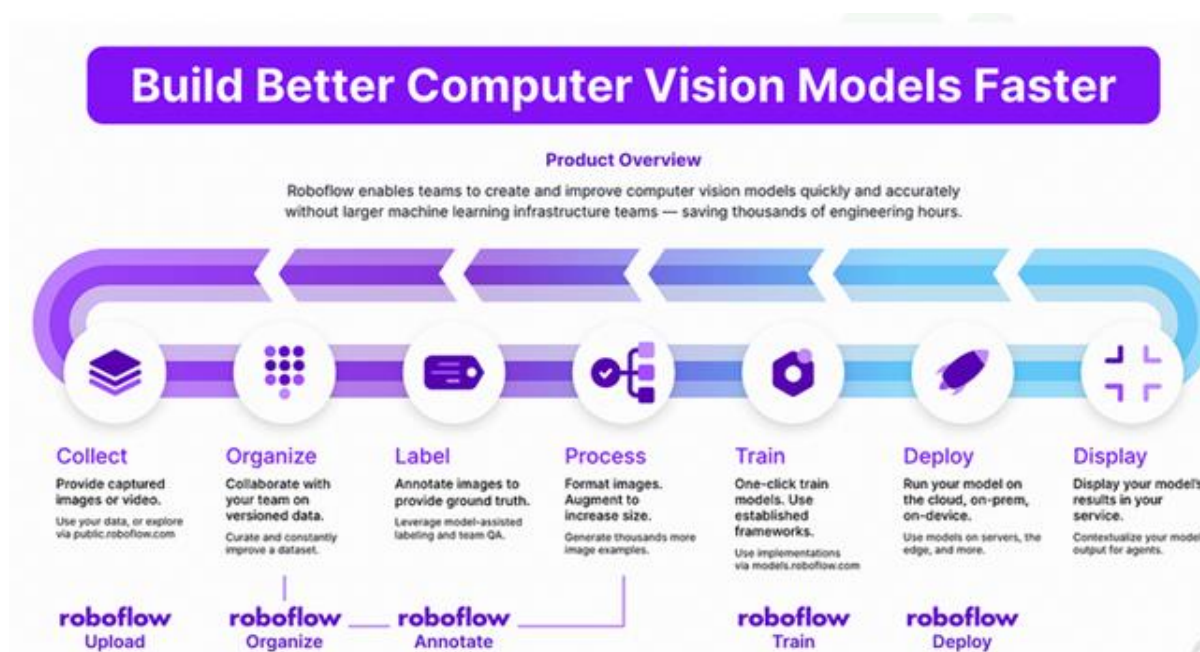


Fig 4. Figur over computer vision modeller, og hvordan man træner dem (*Roboflow, 2023*).

Som vist på billedet, står der ude til højre "Collect", her skal man uploade billeder eller en video. Dette er det eneste man behøver at uploade for at begynde. Man har også mulighed for at arbejde med flere medlemmer af gruppen, til at annotere dem, det kaldes for Dataset annotation. Dette er for at gøre processen hurtigere (*Roboflow, 2023*). Med annotering menes det at definere de forskellige elementer, der vises på billedet/videoen. En af fordelene ved Roboflow er, at den understøtter en lang række filformater og integrerer med populære computer vision-biblioteker og frameworks, såsom TensorFlow, PyTorch og OpenCV (*Bhattacharyya, 2020*). Når man er færdig med at annotere, kræver det et klik for at træne modellen. Roboflow er også en fleksibel platform, der kan tilpasses til forskellige

anvendelser og scenarier. Det kan integreres med andre systemer og applikationer. Det understøtter også træning og implementering af modeller på forskellige enheder, for eksempel mobiltelefoner. Man kan gemme forskellige versioner af annoterede dataset, for at bruge dem enten sparet eller forbundet med en anden version (*Roboflow, 2022*).

Trin-modellen

Dette afsnit beskriver aspekter af Trin-modellen som vil blive brugt i analysen af vores endelige produkt.

Formålet ved TRIN-modellen er at inspirere analyser og beskrivelser af teknologi, med hovedvægt på teknisk-videnskabelige aspekter af teknologierne (Jørgensen, 2018, s. 6-7). Modellen består af seks trin, som hver især kigger dybere ned i en bestemt teknologi. For at undersøge vores teknologi nærmere vælger vi at gøre brug af nogle udvalgte trin, da ikke alle trin er relevante for vores valgte teknologi. De trin vi har valgt at gå i dybden med er; trin 2 om teknologiske artefakter, trin 3 som omhandler utilsigtede effekter, og til sidst trin 6, der handler om teknologier som innovation.

1. Teknologiers indre mekanismer og processer.
2. Teknologiers artefakter.
3. Teknologiers utilsigtede effekter.
4. Teknologiske systemer.
5. Modeller af teknologier.
6. Teknologier som innovation.

Fig 5: Trinmodellen (Niels Jørgensen, 2018)

Trin to, teknologiske artefakter, omhandler teknologiske genstande som er menneskeskabte, og som ikke eksisterer originalt i naturen. Artefakterne har til formål at transformere naturlige ressourcer som stof og energi, ved brug af viden og erfaring. Dette

er til formål for at opfylde det menneskelige behov. I dette projekt udgør AI-løsningen det primære artefakt (Jørgensen, 2018, s. 7-8).

Trin tre som omhandler utilsigtede effekter. De utilsigtede effekter er de risikoer der kan forekomme ved brug af en teknologi. Det er relevant at kigge på de utilsigtede effekter, for at kunne danne sig en bedre forståelse for, hvordan brugen af en ny teknologi kan have nogle påvirkninger på forskellige mennesker. Nogle mennesker ser teknologien som en fordel og ønsker at fremme dens udbredelse, for andre kan det opfattes som en ulempe, hvilket fører til en modvilje mod teknologien og ønsket om at bremse dens udvikling (Jørgensen, 2018, s. 10).

Det sidste *trin*, *seks*, fokuserer på teknologiers innovation. Innovation handler om implementering af nye eller forbedrede produkter, produktionsprocesser eller organisationsformer. Det indebærer at identificere drivkræfter og barrierer for teknologiens udbredelse. Teknologiens formål er typisk at skabe en fordel, og realiseringen af denne fordel fungerer som en drivkraft bag dens udbredelse. Der kan dog også være barrierer, der forhindrer udbredelsen, såsom utilsigtede effekter (*Trin tre*) eller andre faktorer (Jørgensen, 2018, s. 9).

Vidensbidrag

Dette afsnit gennemgår en række teoretisk materiale, og uddyber begreber og forståelse fra dem. De teorier som bliver forklaret vil senere danne grundlag for vores analyse og senere diskussion. Herunder vil vi derfor gerne angive vigtige teorier til at svare på arbejdsopgave 5: "*Hvilken betydning har vores netværk haft på vores projekt, og hvordan bruger vi det?*", hvorpå, som vi senere gerne vil bruge til at analysere vores netværk.

Netværksteori

Dette afsnit uddyber en række teoretiske forståelser indenfor netværksteori. De er udvalgt på baggrund af de begreber som de definerer, og som vi har bedømt, kan være fordelagtige at benytte, når vi vil udforske vores netværks vigtighed under projektets udarbejdelse.

3XA

I vores projekt har vi, som tidligere nævnt, flere forskellige samarbejdspartnere, hvilket har gjort, at vi igennem vores projekt har skabt et netværk. Dette er derfor vi har valgt at gå i dybden med netværksteori, herigennem triple a modellen, som er en model der kan bruges til at analysere netværker og er specielt god til at analysere påvirkningen de forskellige aktører har på produktet/teknologien netværket omgår.

Triple A modellen består af “Assemblage”, “Affordance” og “Agency” som er faktorerne der er med til at beskrive relationerne i et netværk. Tilsammen giver de en forståelse for, hvordan et produkt kan påvirkes og beskriver enkeltvis, hvordan hver enkelt aktør har indflydelse (*Gulbrandsen & Just, nd*).

Assemblage er beskrivelsen af hvordan relationer opstår mellem aktører i et netværk, disse faktorer beskriver grundstenen af netværket og er med til at forklare hvilke aktører der er med i netværket, og hvordan forbindelserne er skabt. Det kan være udfordrende at skabe overblik over komplekse netværk og finde ud af hvor det starter og slutter, og vi bruger derfor assemblage til at danne os et overblik.

Affordance er den faktor, som beskriver de muligheder for handling, der findes for de enkelte aktører. Her er det muligt at kigge på hvilke kompetencer og individuelle egenskaber hver aktør bringer til netværket, og hvordan de påvirker allerede eksisterende forbindelser mellem aktørerne i netværket.

Agency handler om, de valg som er tilgængelige og hvilke valg der bliver truffet. De enkelte aktører, som er med til at forme og påvirke netværket, har alle mulighed for at påvirke det miljø de befinder sig i, men hvad er begrundelsen for de valg de tager? *Agency* fokuserer på aktørernes evne til at handle og træffe beslutninger, der bidrager til udviklingen af netværket. Her er det også vigtigt at gå i dybden med hvilke motivationer der er i spil for hver aktør - og forstå, at de muligheder de vælger at agere på, ikke påvirker antallet af muligheder der er tilgængelige.

Ved at anvende Triple A modellen får vi en dybere forståelse af netværks dynamikken i vores projekt. Vi kan identificere hvilke aktører der er involveret, hvordan de bidrager og hvilke valg de træffer. Dette hjælper os med at forstå, hvor effektivt og produktivt vores netværk er, når alle aktører spiller en rolle i at nå vores mål - og hvor vores vidensdannelse opstår. Vi vil bruge modellen i analysen af afsnittet til at trække forbindelser i vores netværk og forstå hvordan vi er endt ud med det projekt som vi har lavet, og hvordan vores projekt kunne have set anderledes ud, havde vi været i et andet netværk, eller truffet andre valg. Vi vil senere argumentere for, at vores netværk har påvirket vores tilgang til projektet, og vi mener at et anderledes netværk ville have skabt et andet produkt.

Anti-disciplinær videnskab

Dette afsnit omhandler anti-disciplinær videnskab som beskrevet i bogen Kollaboration (Pedersen et al 20xx . bla bla). Begrebet skaber forståelse for vores projekts udfoldelse og Vidensdannelse samt giver indsigt i hvordan vores projekt ikke er bundet til en til én faglighed.

Anti-disciplinær forskning er en ny og mindre udbredte form for forskning. Denne form for forskning kommer fra en tradition som er centreret omkring Bostons MIT Media Lab, hvor forskere skaber både nye løsninger, men også arbejder med menneskelige problemer i stedet for at have fokus på, hvor disciplinernes viden hører hjemme (*Budtz Pedersen, Martiny, Hansted & Wested, 2019*). Hvis vi tager “interdisciplinary work”, som er modsætningen, fokuseres der på mennesker fra forskellige discipliner arbejder sammen. Anti-disciplinær forskning er hvor mennesker eller ting ikke hører indenfor traditionelle

akademiske discipliner, men hvor studieområdet har egne frameworks og metoder (*Budtz Pedersen, Martiny, Hansted & Wested, 2019*). Herpå handler det om at samle eksperter med forskellige egenskaber, og som er interesseret i forskellige fagområder, så man kan opnå en anderledes måde at se tingene på (*Budtz Pedersen, Martiny, Hansted & Wested, 2019*). Ito beskriver discipliner som små sorte noder på et papir omfanget af en hel masse hvidt rum uden struktur, hvor anti-disciplinær videnskab er til for at fylde de hvide rum imellem de forskellige discipliner, hvorpå manglen på veldefineret struktur er her hvor den antidisciplinære forskning opstår (*Budtz Pedersen, Martiny, Hansted & Wested, 2019*). Med denne måde for forskning mener Ito, at man undgår hyper-specialiserede eksperter som har det svært med både at samarbejde og kommunikere med eksperter fra forskellige akademiske områder (*Budtz Pedersen, Martiny, Hansted & Wested, 2019*). Anti-disciplinær forskning skabes af, at medlemmer i en gruppe underviser og vejleder hinanden i deres erfaringer med projektbaseret forskning, hermed at lade være arbejdsprocesser drevet af “uformel projektbaseret vidensdeling” (*Budtz Pedersen, Martiny, Hansted & Wested, 2019*). Fablab er et eksempel på et miljø der arbejder med forskellige fagområder uden at være bundet til et speciale. Vi kommer til at nævne hvordan vores brug af anti-disciplinær videnskab, gennem Fablab, er blevet brugt i vores proces, senere i rapporten.

Kollaboration, Kooperation

Begreberne kollaboration og Kooperation bliver klargjort i dette afsnit. Senere vil vi diskutere vores vidensbidrag, hvor vi vil bruge begreberne.

Videns-dannelse og -deling bliver ofte anset for at være en klar og tydelig proces, som er implicit forstået af dets brugere. Desværre er dette ikke altid tilfældet, da forskellige aktører i et netværk har forskellige agendaer og mål med deres deltagelse i netværket. For yderligere at forstå hvordan vidensdannelse opstår, hvad der hindrer den og hvilken rolle de forskellige aktører spiller i netværket, gør projektet brug af teorien om Kollaboration, som Pedersen et al beskriver som værende: “... *vidensamarbejde med det formål at udvikle nye fælles løsninger.*” (*Budtz Pedersen, Martiny, Hansted & Wested, 2019*). Der er

også andre måder at definere de følgende begreber på, denne bogs begreber bliver brugt i løbet af resten af opgaven.

For at forstå hvordan teorien bliver brugt i projektet, er det yderligere relevant at forstå konceptet om Kooperation, som i denne netværksteori bliver præsenteret som modstykket til Kollaboration. I Kooperation, søger projektgruppen også at opnå en løsning, eller ny viden - men i modsætning til Kollaboration, er opdelingen af opgaver langt mere tydeliggjort.

Man kan derfor sætte de to teorier om netværk op mod hinanden i denne instans, og sammenligne forskellene. Målet med Kollaboration er at revurdere de videnskabende processer i en gruppe, med det mål at finde nye løsninger på problemstillinger. Ved brugen af Kollaboration sker der her en udvikling af individets, såvel som gruppens interne arbejdsprocesser, hvor det fælles mål bliver vidensdannelse og deling.

Opstillet i punktform kan forskellene på de to, på trods af mulige overlap, stilles op som følgende:

- **Kooperation:** Kooperation er ofte mere målrettet mod opnåelse af et specifikt resultat eller mål gennem samarbejde. Det indebærer en opdeling af opgaver og ansvar mellem parterne for at opnå det ønskede resultat.
- **Kollaboration:** Kollaboration fokuserer også på at opnå mål, men det har en stærkere betoning af fællesskab og generering af ny viden. Det handler om at dele ideer, viden og ressourcer for at opnå et resultat, der går ud over det, som hver enkelt part ville kunne opnå alene.
- **Kooperation:** Kooperation kan involvere en vis grad af interaktion og samarbejde mellem parterne, men det kan også være mere opdelt, hvor hver part udfører deres tildelte opgaver og ansvar uden nødvendigvis at engagere sig dybt i hinandens arbejde.
- **Kollaboration:** Kollaboration indebærer en dybere grad af interaktion og samarbejde mellem parterne. Det indebærer en åben og interaktiv proces, hvor deltagerne aktivt bidrager med deres ekspertise, perspektiver og viden for at skabe noget sammen. Der er en større grad af gensidig udveksling og samarbejde i Kollaboration processen.

Nogle af de gennemgående temaer i Pedersen et al's bog kollaboration, er en transparent vidensdeling og kommunikation, samt den sociale kontrakt mellem dets deltagere. Yderligere er den sociale kontrakt (i modsætning til den formelle kontrakt i Kooperation) en vigtig del af processen. I det sociale rum hvor vidensdelingen foregår, bliver den sociale kontrakt implicit accepteret af dets medlemmer - ved hjælp af en transparente kommunikation og enighed om at finde en løsning på problemet (*Budtz Pedersen, Martiny, Hansted & Wested, 2019*).

Pollen samfundet

I foregående afsnit beskrives hvordan videndannelse opstår i kollaboration. Vi vil endegyldigt diskutere hvordan vidensdannelse har barriere, når kollaboration er begrænset. Hertil har vi valgt at dække teorien om pollen samfundet som svar på den kognitive kapitalisme, og dens beskrevne ideal for vidensdannelse.

Vores projekt trækker på open source vinklen og opfordrer til deling af viden og erfaring, både i vores netværk og efterfølgende med vores færdige produkt. Derfor mente vi at Yann Moulier Boutangs Pollen samfund passede til vores projekt, da der i hans samfunds opfattelse fokuseres på vidensdannelse og vidensdeling. Dette afsnit vil kort redegøre for grund pointerne inde for teorien. Det er værd at pointere at det er et sammentræf at pollensamfundet er indraget i vores projekt om pollentælling, navnet er ren tilfældighed.

Pollen Samfundet bygger på en forståelse af, at verden er overgået fra industriel kapitalisme til kognitiv kapitalisme. (*Kristensen, 2009*) Kognitiv kapitalisme imødekommer en anskuelse om at viden er økonomiseret, altså er der ting hvor værdien er opgjort af den viden som er nødvendig for dens ophav. Men også yderligere, at processerne for værdiskabelse er økonomiseret, "*En kapitalisering af individers og virksomheders immaterielle, kognitive ressourcer, processer og potentialer, men også af samfundets kollektive intelligens* (*Kristensen, 2009*)". I den kognitive kapitalisme ligger en central pointe om, at *vidensøkonomien* er politisk, og at vidensøkonomien er en ny type af økonomi. Her anses viden som værende på lige fod politisk og økonomisk som land, penge

eller andre ressourcer. Derudover anses politik, økonomi og videnskab som værende forbundet tættere end før overgangen til kognitiv kapitalisme. Jens Erik Kristensen skriver, at det dominerende narrativ, er ideen om et videnssamfund og en global økonomi drevet af innovation. Denne fortælling lægger vægt på vigtigheden af konkurrence og fremstiller det med militære termer. Fokus er på at gøre landet mere konkurrencedygtigt globalt set, bevare national enhed og kulturel identitet samt fremme individuel og kollektiv kreativitet og innovation for at trives i den globale økonomiske konkurrence. *“Fælles for disse politiske fortællinger er antagelsen om, at viden i bredeste forstand er blevet den nye og afgørende nationaløkonomiske ressource og den værdikilde, der skal mobiliseres, aktiveres, produktiviseres og optimeres på alle niveauer af hensyn til nationens fremtidige overlevelse i en global økonomi.”* (Kristensen, 2009)

Lars Axel Petersen beskriver i sin artikel (Petersen, 2009) et eksempel hvor amerikanske biavlere i deres forsøg på at opnå større profit, avler en “superbi” som kan producere mere effektivt. Resultatet er en intern succes, og bierne har en direkte positiv indvirkning hos biavlerne. Et problem opstod dog, da det blev klart at biernes pollinering aktivitet var stærkt nedsat. Resultatet var at biavlerne fik megen gavn, men på den bekostning at planteavl manglede den pollinering service som var essentiel for dens eksistens (Petersen, 2009). Lars inddrager dette eksempel for at tegne et billede af de problemer som den kognitive kapitalisme medfører.

Lars Axel Petersen beskriver pollensamfundet, som han selv kalder videnssamfundet *“[...] et kæmpemæssigt bistade, hvor alle arbejder sammen på at samle livsforsøende videnshonning, sideløbende med at de bestøver og befrugter samfundslivet og tilmed bidrager til opbygningen af den trygge, varmende og plastiske voksformation, der udgør arbejdets samfundsmæssige vidensstruktur [...]”*. Ved at anerkende vigtigheden af vidensdannelse og en kultur med åben deling af viden, medfører det, at pollen samfundet kan trives og opnå fremskridt. Når individerne i samfundet "pollinerer" hinanden med deres unikke bidrag, skabes der en sammenkobling, hvor helheden bliver større end summen af dens dele. Dette skaber en kollektiv intelligens og en samlet tilgang mod at løse komplekse problemer.

Direkte på grund af ovenstående, argumenteres der i pollen samfundet for, at viden er den dominerende faktor i økonomien. Viden og dets dannelse danner grundlag for individets udvikling og samfundets kultur - her bliver viden givet en værdi, der ikke er bundet op i en valuta, men snarere for at skabe fremskridt og fremme udvikling kollektivt gennem deling. Alle i samfundet spiller en rolle i at bidrage med deres unikke viden og perspektiver. Ligesom bier, der pollinerer blomster, og hjælper med at sprede pollen, bidrager hvert medlem af samfundet, med deres eget sæt af færdigheder, erfaringer og ideer. For at sikre at man kan skabe god vidensdannelse som trives i pollen samfundet, er det vigtigt at skabe en kultur med åbenhed og tillid, der ikke skaber begrænsninger og barrierer for hvad der er tilgængeligt for den enkelte.

Metode

I dette afsnit vil vi præsentere og beskrive de væsentlige metoder, vi har anvendt i vores projekt. Vi vil først redegøre for pollen-indsamling som en afgørende metode til dannelsen af vores datasæt til brug i AI-modellen. Vi vil give en detaljeret beskrivelse af processen og de specifikke trin, der er blevet fulgt for at sikre en effektiv indsamling og validering af vores pollendata. Derudover vil vi præsentere vores prototyper, som er udviklet gennem en iterativ tilgang. Disse prototyper omfatter både vores machine learning-model prototyper, samt vores fysiske prototyper til digitalisering af pollen. Vi vil uddybe de forskellige iterationer og de tilhørende forbedringer og justeringer, der er blevet foretaget for at optimere både ydeevnen og nøjagtigheden af vores prototyper. Hele metodeafsnittet afrunder arbejdsspørgsmål 3: *“Hvad er objektgenkendelse, og hvordan har vi brugt YOLOv8 på digitalisering af mikroskop, til at detektere og klassificere pollen, vi selv har samlet?”*. Med objektgenkendelse forklaret tidligere i rapporten, vil vi derfor gennemgå hvordan vi har brugt YOLOv8, samt hvordan vi har digitaliseret mikroskopet så vi kan bruge machine learning på det.

Pollen indsamling

I dette afsnit vil vi gå i dybden med hvilken indsamlingsmetode vi har brugt, når vi skulle samle vores pollen til vores eget datasæt. Herunder vil vi gennemgå, samt analysere hvilke pollenarter vi har arbejdet med, samt hvordan sæsonen har haft indflydelse på dette. Til sidst vil vi også gå kort over hvilken indflydelse vores manglende samarbejde med Astma-Allergi Danmark har haft på vores projekt. Det giver kontekst til, hvordan vi har digitaliseret vores pollen.

Vores indsamlings metode vi endte med at gøre brug af for at indsamle vores pollen, var en teknik vi lærte af Jeff Ollerton. Hermed tog vi en petriskål og rystede birkens rakler ned i en skål, hvorpå vi kunne se pollen i form af en gullig farve nede i skålen. Denne metode gjorde vi også brug af, da vi skulle samle vores mælkebøtte-pollen, ved at ryste mælkebøtte blomsterne ned i en petriskål. Under dette var disse to pollentyper selvfølgelig separeret i hver sine petriskåle.



Fig 6. På billedet er vi i gang med at indsamle birkepollen ved at ryste birkens rakler ned i en petriskål, og hermed samler pollen






Fig 7. Her ses den samlede pollen nede i en petriskål, samt en skål med birke rakler i

Et vigtigt element at tage stilling til når vi skulle vælge hvilke typer af pollen vi ville arbejde med, som Ollerton også informerede os om, er pollensæson. Eftersom forskellige typer af pollen først kommer frem i forskellige sæsoner, er vi derfor begrænset i hvilke arter vi kunne indsamle. Vi blev informeret af Ollerton om, at på det tidspunkt vi skulle indsamle vores pollen, var det birke sæson, så dette havde derfor indflydelse på vores valg. Yderligere fandt vi ud af senere i projektet at vi gerne ville indsamle én yderligere type pollen til at se om vores AI kunne kende forskel på forskellige arter, så derfor valgte vi mælkebøtten, eftersom de var over det hele på det tidspunkt vi skulle indsamle.



*Figur 8. Birk pollen under et mikroskop.
Billedet er selvtaget*



*Figur 9. Mælkebøttepollen under et mikroskop.
Billede er selvtaget*

På billederne ovenfor kan vi se både den birk- og mælkebøtte pollen vi havde samlet under et mikroskop, hvorpå billedet er taget med en iPhone. Hvis vi kigger på birkepollenet til at starte med, kan vi se at de ofte tager en meget distinkt trekantet form, og har en masse smuds eller pletter i midten. Denne pollentype er meget ensformet, som er et godt aspekt når vores AI skal trænes på denne type. På den anden side har vi mælkebøttepollenet, som er forskelligartet i dets form. Mælkebøttepollenet fremstår her som omringet af en spids struktur og kan have mange forskellige former og størrelser. Under dette kan de fremstå både med en meget distinkt gullig farve eller som helt gennemsigtige og grå. Dette er derfor ikke et godt aspekt ved denne pollen art, da det kan forvirre vores AI når den skal trænes. Efter et møde med Ollerton nævnte han også at mælkebøttens pollen kan være en mærkelig art, da kun nogle pollen partikler fra bøtten kan være levedygtige, da de selvbestøver, altså at en bøtte både har feminine og mandlige organer (*FOTA, 2021*). Dette feminine og mandlige aspekt ved bøtten kaldes også *Heterospecific pollen deposition* (HPD) (*Lopes et al., 2022*). Under dette ser vi også langt flere elementer i mikroskopet som ikke er mælkebøtte pollen, og dette regner vi med at have kommet fra bier og insekter som har slæbt andre arter af pollen eller former for jord på bøtten. Dette er derfor heller ikke helt optimalt for vores AI, eftersom vi gerne ville have en petriskål kun med

mælkebøtte pollen. Vi kom uden om det, ved kun og annotere mælkebøttepollenet, da vi skulle træne vores AI.

Et andet aspekt at belyse er vores manglende samarbejde med Pollen Allergi Danmark. Pollen Allergi Danmark ville her have været nyttig i at træne vores AI, da de allerede havde et stort datasæt med tydelig billeder af forskellige former for pollen arter. Dette ville derfor have været nyttigt at tage brug af når vi skulle træne vores AI. Eftersom vi ikke har haft mulighed for at samarbejde med dem, har vi derfor lagt vores løsning på den ovennævnte metode, men dette kunne stadig have sparet os tid og ressourcer, samt måske have givet os en bedre model, da deres datasæt kommer fra et mere kontrolleret miljø.

Prototyper

I dette afsnit vil vi præsentere vores prototyper, samt de forskellige iterationer, de har gennemgået. Vi vil først gennemgå vores prototyper til vores machine learning-model og beskrive de specifikke iterationer. Vi vil gennemgå væsentlige ændringer, forbedringer og tilpasninger, der er blevet foretaget i hver iteration for at optimere ydeevnen og nøjagtigheden for vores machine learning-model. Dernæst vil vi undersøge vores pollen-digitalisering prototyper, der omhandler fysiske iterationer af metoden til at tage billeder af pollen til træning af vores AI. Vi vil beskrive de forskellige trin og justeringer, for at forbedre kvaliteten og præcisionen af de indsamlede pollen billeder.

Machine learning modellen

Dette afsnit forklarer om udviklingen af vores pollendetekteringsmodel og gennemgår udviklingen af vores datasæt. Afsnittet er opdelt i to prototyper og beskriver processen samt de valg vi har truffet for at nå i mål med den endelige model.

Iteration 1

Prototype 1: Model på Kaggle dataset

Vores indledende fremgangsmåde var at efterfølge FabLabs “guide til artificial intelligence in a microscope” (*Thorning, 2020*), hvilket er det blodcelle identificerings projekt som inspirerede os. Vi blev informeret af vores tekniske vejleder Bo Thorning, at han var usikker på om deres guide var optimal da projektet var 3 år gammelt og udviklingen inden for machine learning i mellemtiden havde gjort store fremskridt.

Deres model var skrevet i Google Colab, hvilket betød, at vi kunne kopiere deres projekter til en start. Deres projekt brugte YOLOv5, hvor vi ville bruge YOLOv8 da den er blevet bekræftet som marginalt bedre (*Jocher, n.d.*). Selvom FabLabs colab projekt var veldokumenteret, var det specifikt bygget til deres datasæt. Vi besluttede derfor at bygge på et mere simpelt kodeeksempel fra Github bruger *deepakato02* (*Deppakat 002, n.d.*). Med dette eksempel kunne vi hurtigt få hans eksempel datasæt op at køre. Det gjorde os i stand til at installere de rigtige python biblioteker som var nødvendige til opgaven, og gav os kendskab til YOLOv8 kommandoer til senere brug. Derudover brugte eksemplet også et python bibliotek som forbandt koden til Google drev, hvilket betød at vi kunne arbejde på vores model samt datasæt over skyen, i stedet for på én computer. Dette har tilladt kollaboration mellem gruppens medlemmer.

Koden

Dette afsnit gennemgår skridt for skridt den python kode som vi bruger til vores pre-processing af at splitte dataen i træning og validering. Vi gennemgår det for at give indsigt i hvordan sådan en datasæt-opdeling konkret kan se ud, og hvordan vi har valgt at udføre vores preprocessing.

Kodesproget er python, det er det som YOLOv8 kommandoer kører i. Vi har valgt at skrive koden i Google Colab, det var der *deepakato02*'s kode originalt var skrevet, og det gør det muligt at dele vores kode imellem alle i gruppen over skyen.

Formålet med koden er at opdele datasættet i 80% træning og 20% validering. Normalt vil man yderligere have et testsæt, men på grund af vores iterative tilgang, har vi taget billeder samme tid som vi har trænet modellen. Det vil sige, at når vores model er færdigtrænet, har vi nogle nye billeder, som vi så kan teste modellen på. Derefter kan vi træne modellen på alle vores nye billeder inklusiv de gamle, hvorefter processen gentages.

Den første linje kode vi skriver, bruger vi til at downloade Ultralytics - der et python bibliotek der giver os mulighed for at bruge pre konstruerede API'er:

```
!pip install ultralytics
```

Koden bruger en række biblioteker, som nødvendigvis skal installeres, heriblandt Ultralytics. Biblioteket indeholder YOLOv8 kommandoerne.

```
## importing required libraries
import os
import shutil
import random
!pip install tqdm --upgrade
from tqdm.notebook import tqdm
```

Vi skal bruge adgang til computerens styresystem (os), muligheden for at flytte, slette og kopiere filer(shutil) og (random) for at generere tilfældige tal.

```
from google.colab import drive
drive.mount('/content/drive')
```

Vi har gjort brug af Google Colab's mulighed for at forbinde med Google drev (fildelingsservice) så vi kan arbejde på koden i fællesskab i gruppen. For at forbinde koden med vores google drev må vi importere biblioteket drive og angive en sti til vores Google drev filer.

```
train_path_img = "./yolo_pollen_data/images/train/"
train_path_label = "./yolo_pollen_data/labels/train/"
val_path_img = "./yolo_pollen_data/images/val/"
val_path_label = "./yolo_pollen_data/labels/val/"
```



```
test_path = "./yolo_pollen_data/test"
```

Vi angiver stier til mapper, som senere skal indeholde vores splittede datasæt. Vi laver mapper med billeder (images) og annotering filer (labels) for både træning og validering. Vi gør brug af deepakatoos train_test_split metode.

```
def train_test_split(path,neg_path=None, split = 0.2):
```

Opdelingen påbegyndes.

```
print("----- PROCESS STARTED -----")
files = list(set([name[:-4] for name in os.listdir(path)]))
```

Alle billederne bliver talt, i det tilfælde der er nogle med det samme navn bliver de ikke talt to gange.

```
print (f"--- This folder has a total number of {len(files)} images---")
```

Vi viser hvor mange billeder der er i mappen.

```
random.seed(42)
random.shuffle(files)
```

Vi blander filerne, så de er i en tilfældig rækkefølge, når vi deler dem op.

```
test_size = int(len(files) * split)
train_size = len(files) - test_size
```

Vi finder ud af hvor mange billeder der skal være i test-sættet og træningssættet. Man kan variere rationen gennem den variabel der hedder split.

```
os.makedirs(train_path_img, exist_ok = True)
os.makedirs(train_path_label, exist_ok = True)
os.makedirs(val_path_img, exist_ok = True)
os.makedirs(val_path_label, exist_ok = True)
```

Vi laver mapper til de filstier vi angav før.

```
### ----- copying images to train folder
for filex in tqdm(files[:train_size]):
    if filex == 'classes':
        continue
    shutil.copy2(path + filex + '.jpg', f"{train_path_img}/" + filex +
'.jpg' )
    shutil.copy2(path + filex + '.txt', f"{train_path_label}/" + filex +
'.txt')
    print(f"----- Training data created with 80% split
{len(files[:train_size])} images -----")
```

Koden gennemgår billede og annoterings filerne en for en og kopiere dem til de mapper der er lavet.

```
### copytin images to validation folder
for filex in tqdm(files[train_size:]):
    if filex == 'classes':
        continue
    # print("running")
    shutil.copy2(path + filex + '.jpg', f"{val_path_img}/" + filex +
'.jpg' )
    shutil.copy2(path + filex + '.txt', f"{val_path_label}/" + filex +
'.txt')
    print(f"----- Testing data created with a total of
{len(files[train_size:])} images -----")
    print("----- TASK COMPLETED -----")
```

De resterende filer er kopieret til valideringsmappen.

```
train_test_split('/content/drive/MyDrive/Bachelor-
Projekt/birchDandel/data/')
```

Sådan benytter vi funktionen på et drev hvori vores datasæt som vi har downloadet efter er blevet annoteret i Roboflow.

2. Fandt Kaggle datasættet

Efter at undersøge vores problemfelt undersøgte vi muligheden for at bygge en model baseret på et datasæt som allerede var lavet og annoteret. I denne process fandt vi ét dataset lavet af Natalia Khanzhina (*Khanzhina et al., 2022*) som indeholder 7750 billeder af 20 pollenarter. Datasættet passede umiddelbart til vores brug - men pollenen på billederne er farvet med fuchsin, et farvestof ofte brugt under mikroskop. Vi havde ikke adgang til fuchsin i vores iterationsproces.


3. Trænede en model

Vores preprocessing af billederne fra Natalia Khanzhinas et al.'s datasæt startede ved at konvertere annoterings formatet som de brugte. Deres annoterings format var to store CSV (Comma separated values) filer. En CSV fil kan sammenlignes med et excel dokument, med rækker og kolonner, blot separeret med kommatering rettere end inddelt i kasser. I en CSV fil ville navnet på en billedfil efterfølges af koordinater for bounding-boxes og en anden CSV fil holde styr på de classes som var i de bounding-boxes. Den samme information bliver brugt af YOLOv8, men den bruger én tekstfil for hver billedfil, og så en YAML fil til at holde styr på classesne. Denne konvertering lavede vi lave i Roboflow, da den har en funktion til netop dette. Resultatet var at vi havde 7750 billeder, 7750 annoteringsfiler og én YAML fil som vi kunne benytte i deeptool2's kode.

Når datasættet er opdelt i de rigtige filtyper, bruger vi python kode (beskrevet tidligere i opgaven) til at opdele datasættet i træning (80%) og test split (20%).

4. Lavede eksperimenter med Kaggle model.

Vi startede med at bruge modellen på vores webcam billeder, med meget ringe resultater. På ingen af billederne blev der registreret nogle pollenkor. Da vi fik gode billeder af vores birkepollen gennem telefon-billederne, var resultaterne heller ikke imponerende. Langt de fleste billeder var uden detektion, med enkelte detektioner med forkerte klassificeringer.



Vi vurderede at vores model var ude af stand til at bruges, i den kontekst vi bruger den. Dette kan blandt andet skyldes brugen af fuchsin, den røde farve, som betød at modellen ikke kan se nok sammenligninger mellem vores billeder og Natalia Khazhinas.

Iteration 2

Prototype 2: model på eget dataset

I dette afsnit vil vi have fokus på vores prototype nr.2, af vores machine learning model, hvorpå vi gjorde brug af vores eget datasæt, i stedet for datasættet fra Kaggle.

1. Samlede eget data

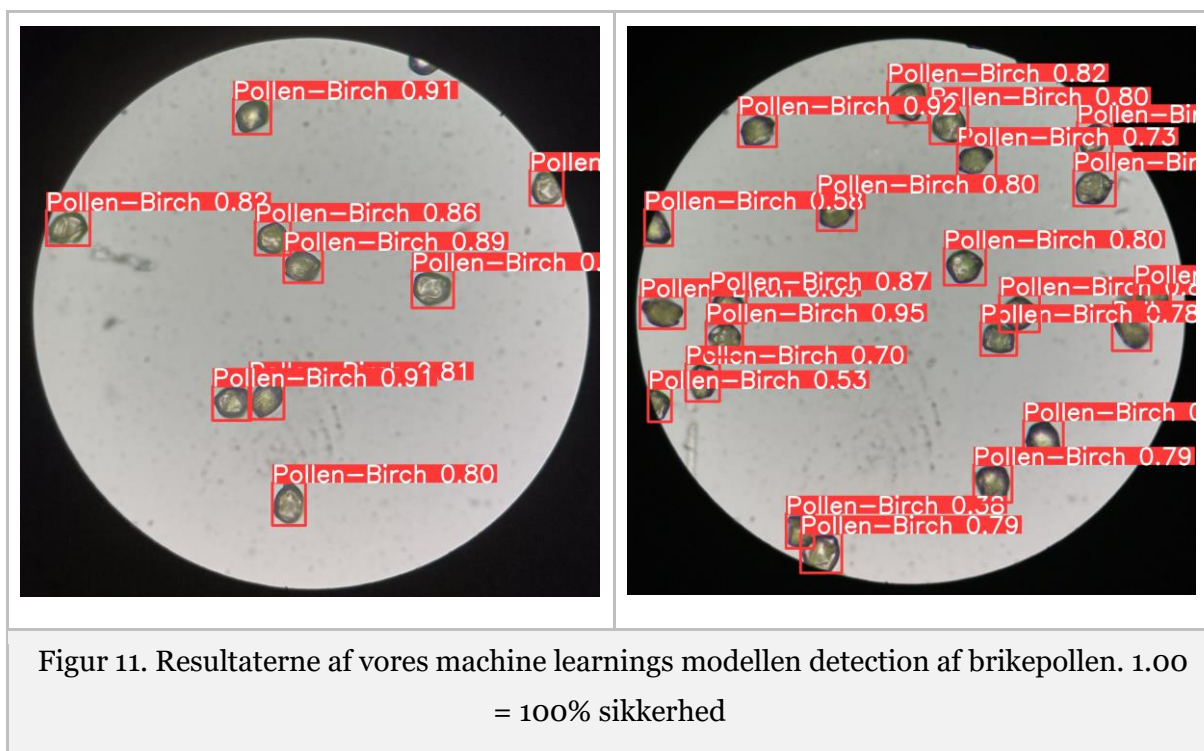
I denne tilgang til at lave en machine learnings model, havde vi besluttet os for at lave en model som er trænet på eget opnået datasæt. Dette gjorde vi da vi igennem vores nuværende netværk ikke havde mulighed for at arbejde med fuchsin, som der farvede pollen partiklerne i datasættet fra Kaggle. Dette leder så til at hvis vi tog vores gamle machine learning model og testede den på vores egne pollen billeder (pollen uden fuchsin), ville modellen være ubrugelig i vores usecase. Derudover underlægger vores problemformulering også at projektet skal have en open source tilgang, hvori at en person som er interesseret i at lave undersøgelser omkring pollen igennem AI, også skal have adgang til de ressourcer som vi fremlægger. Under dette ville en model trænet på fuchsin

(som hverdags mennesket ikke vil have adgang til), gå imod vores problemformuleringstilgang og vores mål med projektet.

Vi indsamlede derfor birkepollen gennem feltarbejde og tog 98 billeder af pollenpartiklerne igennem et mikroskop til at opbygge vores datasæt.

2. Ny model trænet på birk- og mælkebøtte-pollen separat

Da vi havde indsamlet vores datasæt på de 98 billeder af birkepollen, skulle modellen efterfølgende trænes på dette datasæt. Dette gjorde vi ved at annotere billederne af birkepollen på RoboFlow. Da vi havde trænet vores model på birk, tog vi nogle nye billeder af birkepollen, for at se hvor god modellen var til at opspore birkepollen på de nye billeder.




Som ses på ovenstående billede var vores model meget god til at detektere birkepollerne på vores nye billeder. Modellen var endda så god, at den typisk lå omkring de 80-90% sikkerhed i dens beslutning og er endda også korrekt i dens beslutning efter at have gået dens resultater igennem. På trods af modellens succes i at detektere birkepollen, er det stadig vigtigt at være kritisk over for modellens succes. Vi blev derfor i tvivl om at modellen faktisk vidste hvordan birkepollen så ud, eller om den bare noterede alle former for partikler på billedet som birk. Vi skulle derfor finde en måde at bekræfte denne hypotese


for at se om modellen faktisk virkede. Vores metode for at teste dette var, at finde en anden type pollen som modellen skulle trænes på, så vi kunne finde ud af om modellen også kunne klassificere de forskellige typer af pollen. Vi valgte mælkebøtte pollen, da det var en af de eneste tilgængelige pollen arter på daværende tidspunkt i sæsonen og indsamlede pollen fra dem. Vi tog her 102 billeder af mælkebøtte pollen som vi annoterede på RoboFlow for at træne vores machine learning model.

3. Eksperimenter med ny model

Som nævnt før kunne vi ikke bevise at AI'en kunne klassificere arter af pollen med kun én pollen art, så derfor inddrog vi mælkebøtte pollen for at bevise dette. Dette foregik ved at tage én petriskål med birkepollen og én petriskål med mælkebøtte pollen og blande dem, så vi kunne tage nogle billeder med mikroskop med begge arter til stede. Herpå kunne vi finde ud af om vores AI var god til at differentiere de to arter fra hinanden.




Figur 12. Eksempel på god detektion, men dårlig kvalificering.



Figur 13. Eksempel på god klassificering af pollen-arter, men dårlig detektion af pollen.

Som vi kan se på ovenstående billeder er vores model ikke nær så godt som den var, da vi kun havde birkepollen inden i vores datasæt. På Figur 12, ses der her at modellen er god til at detektere alle pollen partiklerne, men er dårlig til at kvalificere pollenen som de rigtige arter. På Figur 13, ser vi det modsatte, hvor den er dårlig til at detektere alle pollen

partiklerne, men god til at klassificere dem. Det leder os til at sige at vores model lidt utilregnelig, da den fungerer godt nogle gange, men andre gange halter i dens resultater. Herunder er den også mere usikker i dens resultater af detektering og klassificering, som vi kan se på en graf.



Figur 14. Her ses en graf af hvor sikker vores model er på dens resultater (x-aksen: confidence). F1 er her en sammenblanding af præcision og recall (y-aksen).

Hvis vi kigger på ovenstående graf, kan vi se at vores model er meget mere sikker i birkepollen, frem for mælkebøtte pollene. Dette viser også at den er mere hyppig til at have fejl på mælkebøtte pollen, end den er ved birke pollen. Dette vil vi komme mere i dybden med når vi analyserer vores data.

Pollen digitalisering

I følgende afsnit undersøger vi nærmere hvordan vi har digitaliseret pollen partiklerne ved at følge processen fra træ til computerskærme, og hvordan vi har bygget vores model til at analysere dem.

Iteration 1

For at realisere konceptet med at anvende kunstig intelligens til objektgenkendelse for identifikation og tælling af pollen-partikler, har vi valgt at udvikle en serie af prototyper. I den første iteration af prototypen var formålet at indsamle billeddata fra et mikroskop, foretage annotation af dataene og derefter køre vores AI-model på den indsamlede data.


For at opnå dette anvender vi et stereoluopingsmikroskop til at opnå fokusering af pollenkornene. Vi har også 3D-printet en holder til et webcam, som vi kan forbinde med en makro adapter udstyret med en zoomlinse. På grund af vores valg af et stereoluopingsmikroskop manglede vi en zoomlinse med 10x forstørrelse mellem mikroskopet og webcams. Den 3D-printede komponent fungerer derfor som en holder til webcams og linsen, som illustreret i bilag X nedenfor.



Fig. 15 (ik1xpv, 2020)

Iteration 2

Efter den første iteration af vores prototype blev vi opmærksomme på, at det valgte webcam var udstyret med et vidvinkelobjektiv. Dette gør vores proces mere kompleks, da vi ikke var i stand til at opnå en skarp fokusering gennem adapteren. Som et resultat gik vi videre til den anden iteration af vores prototype. Vi udførte eksperimenter med alternative kameraer og konstaterede, at vi opnåede de bedste resultater med et iPhone 14 Pro-kamera. Derfor reviderede vi vores prototype for at inkludere et telefon-kamera i stedet for et webcam. Nedenfor præsenteres en kort sammenligning af billederne taget med henholdsvis et webcam og en telefon:



Figur 16. Venstre: Billede af pollen taget med webcam. Højre: Billede af pollen taget med telefon.

Webcam-billedet viser en bred synsvinkel og præsenterer et sort område, der skyldes genspejling fra webcams glas. Denne genspejling kan forårsage en hvis forvrængning og nedsætte billedets skarphed og kvalitet.

På den anden side demonstrerer telefon-billedet en betydeligt højere grad af klarhed og fokusering, hvor telefonens software samarbejder med os for at modvirke lyseffekten fra mikroskopet og opnå en mere præcis billedgengivelse. Denne tekniske optimering muliggør en mere præcis og detaljeret repræsentation af objekterne, idet billedet generelt

har mindre forvrængning og opnår en mere nøjagtig fokusering. Herefter var vi i stand til at opnå tydelige og præcise billeder af de pollen partikler, vi havde indsamlet. Disse specifikke pollen partikler fra birketræer var suspenderet i mikroskop olie for yderligere at forbedre billedkvaliteten. Ved at suspendere partiklerne i olien blev billedoptagelsen optimeret, hvilket resulterede i en øget klarhed og detaljegrad af de individuelle pollen partikler ved en zoomfaktor på 400 gange. Denne tilgang muliggjorde en forbedret visualisering af pollen partiklernes struktur og karakteristika, hvilket var afgørende for vores analyse og identifikation af dem.

Iteration 3

I den tredje iteration af vores prototype har vi eksperimenteret med Real Time Object Tracking ved at udvikle et Python-script, der inkorporerer OpenCV og YoloV8. Dette har muliggjort kørsel af en af vores modeller, der er trænet på vores egne data, i realtid. For at implementere Real Time Object Tracking udnyttede vi OpenCV-biblioteket, som er et computer visualiseringsværktøj.

Implementeringen af denne løsning i vores tredje prototype-tilpasning har muliggjort Real Time Tracking, men det var ikke uden udfordringer. I den første kørsel af vores model anvendte vi YoloV8X, som er den største træningsmodel understøttet af Yolo. Desværre stødte vi på begrænsninger i vores hardware. YoloV8X-modellen kræver betydeligt mere processorkraft, end vi havde til rådighed, hvilket resulterede i en gennemsnitlig hastighed på kun ét billede hvert tredje sekund. Selvom vores model var nøjagtig og i stand til at identificere og tælle pollen partikler i realtid, var denne hastighed utilstrækkelig.

Efterfølgende forsøgte vi os med Yolo's mindst krævende model, YoloV8Nano. Med denne model kunne vi opnå en hastighed på op til 15 billeder i sekundet. Desværre var YoloV8Nano-modellen ikke i stand til at identificere pollen partiklerne korrekt. Dette resulterede i mangelfulde resultater og underminerede vores evne til præcis identificering.

Denne udfordring med hardware begrænsninger 'førte os til at erkende behovet for en mere afbalanceret tilgang. Herefter bliver der undersøgt og eksperimenteret med alternative modeller og optimeringsmetoder, der kan opretholde en tilfredsstillende hastighed og samtidig opnå præcis identifikation og optælling af pollen partikler i realtid.

Endeligt produkt og model

I dette afsnit vil vi gerne gennemgå vores endelige produkt som vi har udviklet til vores projekt. Herunder vil følge en grundig beskrivelse af produktet, samt hvordan vi havde forestillet os at produktet skulle bruges i praksis. Dette afsnit afrunder arbejdsspørgsmål 3: *“Hvad er objektgenkendelse, og hvordan har vi brugt YOLOv8 på digitalisering af mikroskop, til at detektere og klassificere pollen, vi selv har samlet?”*.

Vores endelige produkt er en kunstig intelligens model til genkendelse af objekter, som er bygget på af YOLOv8-frameworket. Produktet er blevet trænet til at identificere og tælle specifikke pollen partikler. Gennem udviklingsprocessen har vi opbygget og trænet flere iterationer af modellen, hvor alle dele af vores model er blevet implementeret ved hjælp af programmeringssproget Python. Dette omfatter både træningssekvensen og selve modellen.

Modellen er i stand til at analysere de indsamlede data og kan anvendes til to forskellige pollentyper som er mælkebøtte og birk. Dette indebærer, at modellen er blevet trænet på en tilstrækkelig mængde data, der er blevet indsamlet og kategoriseret specifikt til disse pollenarter - dette blev forklaret i afsnittet om roboflow, annotering og bounding boxes. Ved at udnytte YOLOv8-frameworket og vores tilpassede træningsdata har vi opnået en model, der kan identificere og skelne mellem disse to typer pollen partikler med en vis grad af nøjagtighed.

Vores produkt er umiddelbart udviklet som et hjælperedskab til mennesker der arbejder med pollen og kan her bruges til at gøre arbejdsprocessen hurtigere og nemmere. Under dette kan vores produkt hjælpe med at klassificere og detektere pollen gennem mikroskopet. På samme måde kan dette redskab også hjælpe mennesker der er interesseret i pollen og ønsker selv at lave forsøg igennem deres eget mikroskop ved at hente vores model igennem open-source.




Fig 17. Billederne illustrerer den fysiske arbejdsproces under samling af billeder til vores datasæt

På ovenstående billede er der fremlagt hvordan vores produkt fungerer i praksis. Først kræves det at der bliver indsamlet noget pollen og lagt på en glasplade med noget olie, der kan indsættes ved mikroskopet, hvorpå subjektet selv kan justere på mikroskopet for at opnå det billede af deres valgte pollen som de ønsker (1). Efter dette kan smartphone adapteren med okular indsættes på mikroskopet hvorpå der kan tages billeder til vores model (2). Herefter kan billederne sendes til vores model, og klassificeres og detekteres af vores pollen model. Vi har brugt et simpelt USB stik, til at overføre dataen fra telefonen til computeren. På den anden side kan vores produkt også tage imod billeder af pollen og analysere dem. Dette ville være nyttigt for en virksomhed som Astma-Allergi Danmark, som har bedre redskaber end vores kamera opsætning til at tage billeder af pollen. Herefter kan de blot sætte deres selv-tagede billeder eller billeder fra deres datasæt ind i vores model og derved få klassificeret og detekteret deres pollen partikler. Resultaterne, hvor godt vores produkt kører, samt hvilke pollen arter vores produkt kan klassificere og detektere, vil blive analyseret mere i dybden i analysen afsnittet.

Analyse og Resultater

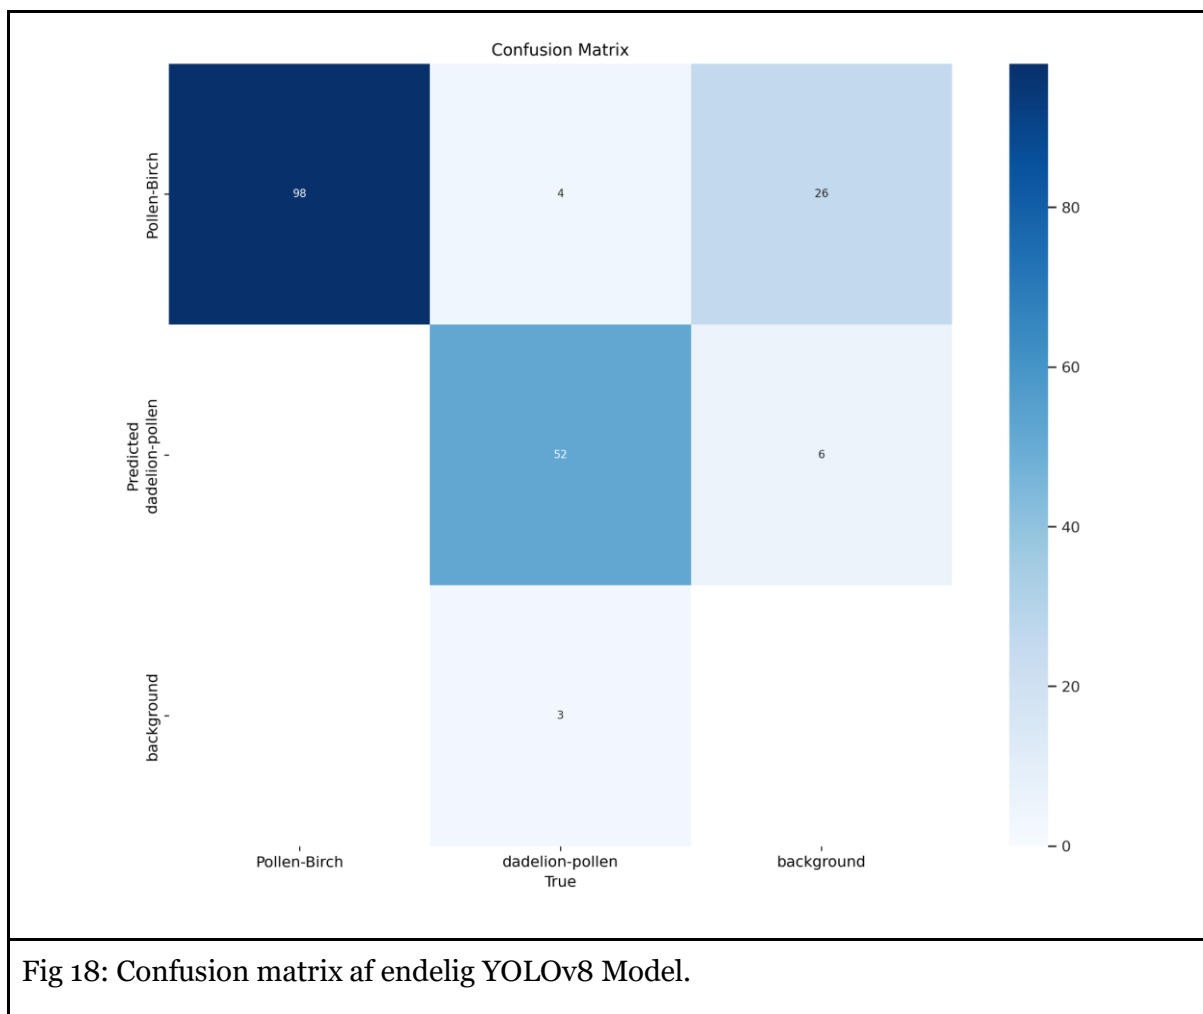
Dette afsnit har til formål at udføre en omfattende og præcis analyse af de væsentlige aspekter i vores opgave. Vi vil benytte teoretiske elementer og analysere disse elementer for at opnå en solid forståelse, der kan danne grundlag for en senere diskussion. I den forbindelse vil vi foretage en analyse af produktet, der omfatter både teknisk- og praktisk evaluering, samt en analyse af trin-modellen og problematikken omkring underfitting/overfitting. Vi vil yderligere foretage en grundig analyse af vores projektstyringsform og fokusere på den betydning som SCRUM har haft for vores projekt. Endvidere vil vi foretage en analyse af vores netværk og undersøge koncepter som anti-disciplinær videnskab, 3XA-modellen og kollaboration i relation til vores projekt.

Produktanalyse

Dette afsnit vil analysere vores endelige model og pollen digitalisering, hvorpå afsnittet er inddelt i en teknisk analyse og en praktisk analyse. Dette afsnit vil derfor have fokus på den analyserende del af arbejdsopgave 4: *“Hvor godt løser vores projekt sin opgave, og hvad bidrager det med?”*. Der vil her gives en forståelse af produktet igennem trin-modellen og give en kritisk analyse af vores færdige produkt, samt en analyse af den tekniske og praktiske del af produkt-evalueringen.

Teknisk evaluering

Dette afsnit gennemgår en teknisk analyse af den endelige YOLOv8 model. Der vil følge en række datavisualiseringer, som påviser præstationen af vores pollendetektionsmodel. For at evaluere vores model har vi brugt YOLOv8's indbyggede funktion til at producere en række grafer som viser målinger på hvordan modellen præsterer.



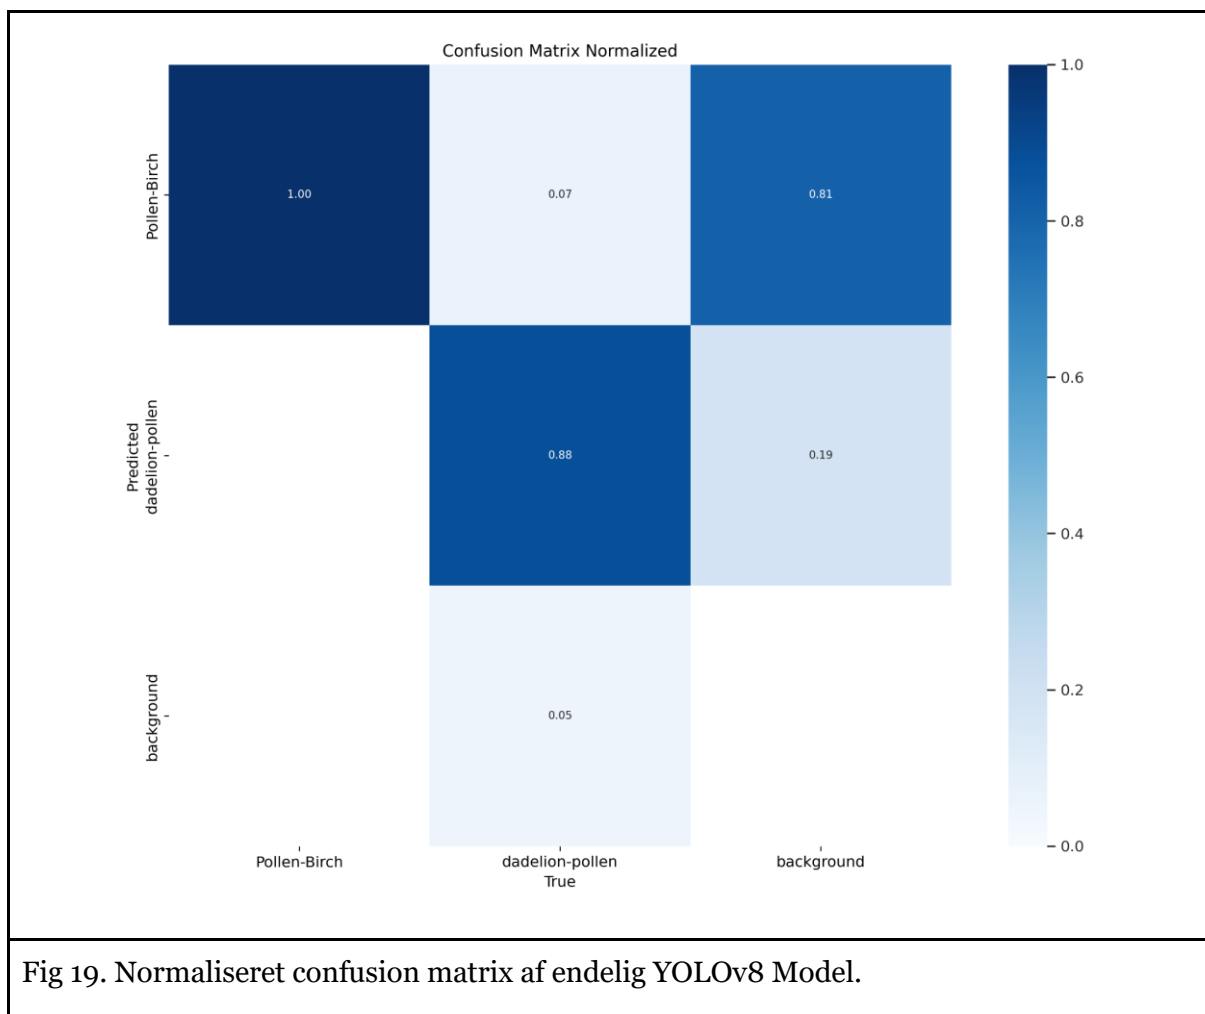
Modellens confusion matrix viser alle *gæt på birkepollen*, hvorpå den har gættet:

- 98 gange rigtigt
- 4 gange hvor den rigtige pollen var mælkebøtte-pollen
- 26 gange hvor der ikke var pollen til stede.

Af alle *gæt på mælkebøttepollen* har den gættet:

- 0 gange hvor det rigtigt var birkepollen
- 52 gange hvor den rigtigt gættede mælkebøttepollen
- 6 gange hvor der ikke var pollen til stede.

Sidst viser matrixen at der var 0 instanser hvor der er gættet baggrund/ingen pollen men hvor der skulle have været et birkepollen gæt. 3 forekomster blev der gættet baggrund hvor der var mælkebøttepollen.



Den normaliserede confusion matrix viser en 1.0 eller 100% rate for birkepollen gæt. Det er en perfekt score, igennem valideringen gætter den altid, når der er forekomster af birkepollen på billedet. Dette er en så god score, at det er mistænkeligt. Det er et signal om at modellen er meget sensitiv overfor birk, og kan være oversensitiv. Hvis scoren er så høj, kan modellen gætte birk, hvor det ikke er forekommende, og det viser sig også er tilfældet. Hvis man kigger på de resterende resultater, så er det meget sjældent at den gætter birk når de skulle have været mælkebøtte ved 0.07 eller 7%. Til gengæld, af gæt hvor modellen tror der er pollen hvor der ikke er noget, så gætter den birkepollen med en rate på 0.81 eller 81%. Det er ikke nok at bruge en 81% rate af forkerte gæt på baggrund, til at vurdere hvor oversensitiv den er. Det er fordi 81% er ud af alle forkerte gæt, ikke hvor ofte den gætter forkert. Det vil sige, gæt hvor der ikke er pollen, men modellen tror det, er birk primært gættet. Når man lægger birk og pollen sammen, vil det altid være 100%.


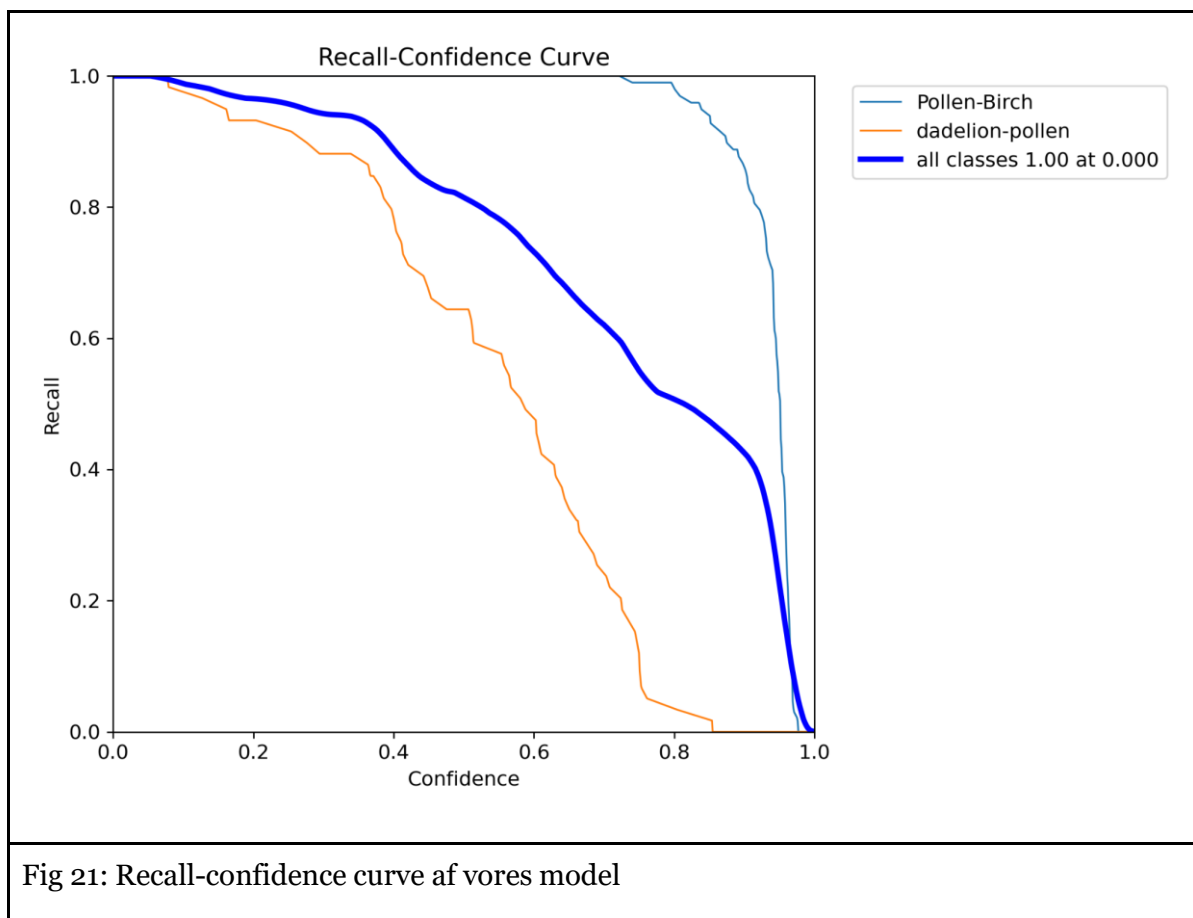


Fig 20: Precision-confidence for YOLOv8 Model.

Modellens Precision-confidence curve viser hvor sikker modellen er på et gæt. Vi kan se at både birk og mælkebøtte pollen vokser hurtigt indtil 20% sikkerhed, hvor den langsomt stiger i precision indtil omkring 80% sikkerhed. Kurven viser at vores model er meget præcis. Allerede ved meget lav sikkerhed gætter den mælkebøtte pollent præcist, hvilket betyder at der ikke skal meget sikkerhed til for at den er god til at gætte dem. Der er dog også balanceret af, at kurven stopper midt i 60'erne. Med mælkebøttepollen får du allerede en præcision på +80% ved en lav sikkerhed. Men med så imponerende en ration signalerer det at man skal være mistænksom over for andre problemer med modellens klassifikation af mælkebøtte pollen. Med birkepollen er præcision- til sikkerheds-ratioen lavere, for at få over +80% præcision skal modellen være over 40% sikker.




Vores model viser at jo højere vi sætter vores sikkerhedskrav, jo færre true positives gætter modellen. Her bliver foregående høje præcisionsrate for mælkebøtte sat i perspektiv.

Recall, altså true positives, falder hurtigt for mælkebøttepollen. Det viser at vores model er meget usikker i sin klassificering af mælkebøttepollen. Hvis du vil have 80% af alle mælkebøttepollen detektioner skal du sætte sikkerheden under 40%.

Her ser den værre præcisionsratio for birkepollen, i forhold til mælkebøttepollen som beskrevet før, ud til ikke at være en større problematik. Det er fordi birkepollenmodellen får 80% af true positives indtil at man sætter *confice* niveauet nær 100%,.

De signalerer at vores birkepollen detektion ikke kræver en særligt høj sikkerhed for at få alle true positives med, til gengæld er vores mælkebøtte detektion mindre sikker og kræver en meget lav sikkerhed på omkring 10% for at få alle true positives med.



Når man kigger på præcision og recall gennem en F1-confidence curve er det meget tydeligt at vores mælkebøtte-data trækker vores models sikkerhedskrav ned. F1 kurven viser at modellen gætter 90% af true positives ved 35% confidence, hvilket er meget lavere end de nær 100% som birke-detektion kræver. Vores YOLOv8 model er derfor optimal forhold mellem præcision og recall ved 35.5% sikkerhed, det kan læses på all classes hvor f1 scoren er 0.9 ved 0.355, eller 35.5% confidence niveau.

Analysen af vores confidence curves har vist at vores model generelt er underfittet, hvor en af årsagerne er, at vores data af mælkebøtte pollen er underfittet. Dette kan skyldes, at mælkebøttepollen har en meget varierende og anderledes udseende, former og farver når det bliver vist under mikroskop, dette resulterer i en manglende evne hos vores model til at generalisere korrekt på disse variationer. Dette fører til en underfitting af vores data, da vores model ikke er i stand til at lære de komplekse mønstre og variationer i mælkebøtte pollen. Billedet nedenunder viser hvordan mælkebøtte pollen har forskellige former og

farver under mikroskop, hvilket gør at vores model har det svært ved at genkende det og være sikker på det.




Fig 23. Billede taget under et mikroskop af 3 forskellige mælkebøttepollen partikler

På den anden side er vores birkepollen data hverken underfitet eller overfitet. Dette skyldes, at birkepollen har en mere ensartet struktur og udseende og former under mikroskopet. Formen og farven af birkepollen er mere ensartet sammenlignet med mælkebøtte pollen, hvilket gør det lettere for vores model at generalisere korrekt på disse data. Derfor ser vi hverken underfitting eller overfitting i vores birkepollen data. Billedet nedenunder viser hvordan birkepollen har ens udseende og klare former under mikroskop sammenlignet med mælkebøtte pollen,




Fig 24. Billede taget under et mikroskop af en gruppe birkepollen partikler

For at forbedre vores models sikkerhed med hensyn til identifikationen af mælkebøtte pollen, har vi i gruppen overvejet at træne modellen på mere mælkebøtte pollen data, der gør vores model mere effektiv. Men på grund af tidspress, har vi valgt at beholde vores model som den er. En anden grund til vi har valgt at beholde vores model som den er, er fordi vores analyse af F1-confidence curve har vist, at vores model er særlig god til at identificere birkepollen, mens den har svært ved at identificere mælkebøtte pollen. Dette afspejles i kurvens form, hvor vores model viser højere præcision og nøjagtighed i identifikationen af birkepollen sammenlignet med mælkebøtte pollen.

Analysen af vores F1-confidence curve giver os værdifuld indsigt i vores models præstation og dens evne til at skelne mellem forskellige pollenarter. Modellen virker til at være god til at identificere birkepollen, men mindre god til at identificere mælkebøtte pollen. På baggrund af vores analyse af de forskellige confidence curves, kunne vi identificere og forstå de specifikke udfordringer, vores model står over for ved identifikationen af

mælkebøtte pollen - hvilket leder til, at vi i fremtiden kan træne modellen på flere variationer af mælkebøtte pollen data, der gør vores model mere bedre og præcis.

Praktisk evaluering

Dette afsnit evaluerer det endelige produkt, pollendigitalisering og YoloV8 modellen. Det tager stilling til hvordan det passer i en pollentællings arbejdsprocess, samt gennemgår teknologiens fordele og ulemper.

Vores tekniske evaluering af vores model viser tydelige problemer med vores Machine Learning model, afhængig af hvilke forventninger man har til den.

Når man observerer analysen af modellens birkepollen-klassificering, og sammenholder det med billeder af modellen kørt på et testsæt, er det dog tydeligt at modellen ikke er uden brugbarhed.





Fig 25. 3 billeder af vores model brugt på nye billeder.

Vores inddragelse af mælkebøttepollen var for at introducere “støj”, et andet element som kunne komplicere opgaven for vores model. Derfor er vægtningen af mælkebøttepollendetektionen mindre essentiel for machine learning modellens use-case. Vores formål er at detektere og klassificere i en pollentællings sammenhæng som den er hos Astma-Allergi Danmark, og det er klart, at der oftest vil være flere forskellige pollentyper i luftefælder afhængig af season.

Pollenkalender

De vigtigste allergifremkaldende pollen i Østdanmark



Pollenkalenderen er udarbejdet af Astma-Allergi Danmark.
Pollenkalenderen er baseret på gennemsnitsværdier fra målestationen i København fra perioden 2011-2020.

Fig 26. Pollenkalender fra Astma-Allergi Danmark (Astma-Allergi Danmark, n.d.)

Til trods for at vores model er oversensitiv for birk, viser den at det er muligt at træne en model til at være meget præcis i klassificeringen af enkelte pollentyper. Det betyder at pollen detektion og klassificerings opgaver i nogen grad, bestemt kan løses af Machine Learning. Da vores overblik over Astma-Allergi Danmarks arbejdsprocess er begrænset til en kort video, kan vi ikke med sikkerhed bedømme hvilke plads vores model ville have i deres pollentælling. Til trods for det vurderer vi at vores model, som den er i sin nuværende tilstand, kan bruges til en indledende scanning af pollentyper på billeder, som kan eftergås af specialister, frem for nu hvor hele processen er specialistens opgave.

Vores YOLOv8 model vil kunne agere som produktivitet søgende og tidsbesparende værktøj, da processen med identifikation og klassifikation er foretaget. Vores resultater peger også på, at med bedre tilpasning af modellen vil den være endnu mere præcis, hvilket kan betyde at med en større indsats i data valg, samt pre-processing, ville vores endelige model også have muligheden for at have større indvirkning på et virkelighedsbaseret problem. Vi kan ikke konkludere hvad der skal til for at processen

bliver helt automatiseret, specielt fordi der også må inddrages en diskussion om hvordan man fordeler ansvar når en Machine Learning algoritme laver fejl, men Machine Learning kan bestemt bruges til at detektere og klassificere pollen.

Vores pollen digitalisering har lille relevans for Astma-Allergi Danmark, men større relevans for andre med objekt genkendelses opgaver under mikroskop. Astma-Allergi Danmark har, ifølge deres video, allerede digitaliseret deres mikroskop. Hver på vores proces viser at sådan digitalisering med telefon-kamera er af en sådan kvalitet, at det kan agere i machine learning sammenhænge, og kan bruges til konkrete problemstillinger.

Analyse af trin-modellen

Dette afsnit søger at komme nærmere ind på hvordan de tre udvalgte trin fra TRIN-modellen er blevet brugt i projektet. De udvalgte trin var det 2, 3 og 6 trin, der henholdsvis identificerer de teknologiske artefakter, de utilsigtede effekter og teknologiens innovation. Dette afsnits inklusion er for at danne en bedre forståelse for teknologien og dens brug.

Trin to fokuserer på de teknologiske artefakter. Det primære artefakt i denne løsning er YOLOv8 modellen, men der er også andre tilknyttede teknologiske artefakter, der er nødvendige for at understøtte og implementere vores løsning. De andre artefakter som mobiltelefonen fungerer som en enhed til at indsamle og overføre billeddata af pollenprøver. Mikroskopet er en vigtig komponent til at generere højkvalitetsbilleder af pollen til analyse og identifikation. Computeren bruges til at behandle og analysere billederne ved hjælp af AI-algoritmen. Hver af disse artefakter har sin egen funktion og bidrager til effektiviteten og præcisionen af teknologien som helhed. Løsningen er udviklet til at automatisere identifikationen af pollentyper, og til at analysere og tælle pollendata ved hjælp af billedgenkendelsesteknologi. Ved at bruge viden og erfaring kan man skabe et artefakt, der automatiserer en kompleks og tidskrævende opgave. Løsningen kan bidrage til at øge effektiviteten i identifikationsprocessen. Mens traditionel manuel identifikation af pollen partikler kræver omfattende arbejde og ekspertise fra menneskelige operatører, kan AI-løsningen udføre denne opgave hurtigere og dertil forbedre præcisionen af identifikationen af pollenarter. Dette sker ved at trække på store mængder data og da

systemet kan genkende mønstre og karakteristika, der er svære at opdage for mennesker. Dette kan mindske fejl og forbedre nøjagtigheden af pollen-identifikationen.

Trin tre fokuserer på de utilsigtede effekter, disse er vigtige at identificere og forstå. Effekterne eller udfordringer er forbundet med brugen af teknologien. En mulig ulempe kunne være, at AI-løsningen erstatter menneskelige operatører eller eksperter, der tidligere udførte opgaven manuelt. Dette kan føre til bekymringer omkring arbejdsløshed eller manglende muligheder for fagfolk, der tidligere beskæftigede sig med pollen identifikation. En anden utilsigtet effekt kan være modstand fra forskellige personer. Nogle mennesker kan støtte brugen af teknologien som, der øger effektiviteten og nøjagtigheden af pollen identifikation. På den anden side kan der være mennesker, der er modvillige over for automatisering og foretrækker den manuelle tilgang. Dette kan skyldes en frygt for fejl ved at den give et forkert pollental, eller manglende tro til selve teknologien.

I trin seks fokuseres der på innovationen af teknologien til automatiseringen af pollen identifikation. Dette trin handler om at undersøge, hvordan teknologien bidrager til at skabe en fordel eller en innovation i forhold til eksisterende løsninger. Løsningen repræsenterer en innovativ tilgang til identifikation og optælling af pollentyper ved at udnytte billedgenkendelsesteknologi. Ved at automatisere identifikationsprocessen kan man opnå flere fordele og forbedringer i forhold til den manuelle metode. En af fordelene ved AI-løsningen er den øgede effektivitet. Ved at automatisere processen spares der tid og ressourcer, da identifikationen af pollenarter kan foregå hurtigere. Dette gør det også muligt for forskere og andre mennesker at få adgang til identifikationsproblemer hurtigere. En anden fordel er den forbedrede præcision, da AI-løsning kan analysere store mængder pollendata og genkende forskellige mønstre. Dette kan også reducere fejl og forbedre nøjagtigheden af pollen-identifikationen, hvilket er særligt vigtigt inden for videnskabelig forskning og allergi-diagnostik. Det er dog vigtigt at være opmærksom på eventuelle barrierer der kan påvirke innovationens fulde udnyttelse. Dette kan omfatte potentielle tekniske begrænsninger, eller manglende accept fra personer.

Samlet set har anvendelsen af TRIN-modellen og analysen af trin 2, 3 og 6 givet et dybere indblik i projektet med automatisering af pollenidentifikation. Analysen har bidraget til en bedre forståelse af de teknologiske artefakter, de utilsigtede effekter og innovationsaspekterne ved teknologien. Dette kan hjælpe os med at optimere

implementeringen, håndtere eventuelle udfordringer og sikre en succesfuld og accepteret anvendelse af teknologien inden for pollenidentifikation.

Projektstyrings analyse

I følgende afsnit analyserer vi hvordan vi har arbejdet agilt med SCRUM og den iterative arbejdsproces, og har brugt det til at udvikle vores prototyper inden for både machine learning og pollen digitalisering. Dette afsnit giver vores bud på arbejdsspørgsmål 2: "*Hvordan skaber man en god projektstyring?*", hvorpå vi vil tage stilling til vores egne erfaringer med projektet.

Hvordan har vi brugt SCRUM til at facilitere vores iterative proces

Vi har valgt at bruge den agile SCRUM tilgang, grunden til vi i gruppen har valgt at benytte os af det, er fordi SCRUM er en metode som har vist at den fungerer optimalt når man arbejder i teams. Vores proces startede med at udvælge en scrum master, der tager ansvaret for møder og oprettelse af sprints.

Som tidligere nævnt, så har vi delt vores prototyper op i to dele; *Machine learning prototype* og *pollen digitalisering prototype*. Disse to prototyper har vi udviklet parallelt, hvor begge prototyper har haft flere iterationer - og ved at bruge scrum-metoden, kunne vi holde styr på udviklingsprocess af begge prototyper ved at opretholde vores sprints løbende.

Til vores første iteration af *machine learning prototype*, har vi identificeret tre konkrete opgaver, der er afgørende for at realisere vores mål. Opgaverne blev oprettet som *tasks* i et sprint vi har kaldt "machine learning 1. iteration". Den første opgave består i at finde et eksisterende datasæt fra Kaggle, og læner sig op af vores eget mål med YOLOv8-modellen. Dette indebærer at foretage en grundig søgning og evaluering af forskellige tilgængelige datasæt for at sikre, at vi får de relevante data til vores formål.

Den næste opgave fokuserer på udviklingen af selve YOLOv8-programmet. Denne opgave indebærer en række tekniske opgaver såsom kodning og testning. Med denne opgave har vi benyttet os af SCRUM frameworket til at opdele opgaven i mindre dele hvor hvert medlem af teamet tager en specifik opgave. Ved at benytte den iterative proces, vil der være mulighed for at få feedback undervejs, hvilket er essentielt for vores produkt udviklingsproces.

Den sidste opgave i vores "1.iteration" handler om træning af vores YOLOv8 model ved hjælp af Kaggle-datasættet. Dette indebærer at anvende machine learning-teknikker og algoritmer til at træne vores model, hvorpå dens præstation bliver forbedret. Herunder har vi udnyttet SCRUM-metodens fleksibilitet til at give løbende feedback som hjælper med at forbedre modellen. Gennem iterativ træning og evaluering ønsker vi at opnå en dybere forståelse af vores model og forbedre dens evne til at identificere de forskellige pollen typer som modellen blev trænet på.

Til vores anden iteration af *machine learning prototype*, har vi fulgt samme proces i vores første iteration, hvorpå vi identificerer konkrete opgaver som teammedlemmerne skal udføre. Vi har oprettet et nyt sprint som hedder "machine learning 2. iteration", som indeholder to tasks. Den første opgave består i at finde pollen og tage billeder af det. Dette er afgørende for at skabe et nyt tilpasset datasæt, der kan anvendes til at træne vores model.

Den anden opgave fokuserer på træningen af vores model ved hjælp af det nye datasæt, som vi selv har indsamlet og digitaliseret. Ved hjælp af forrige sprints og tidligere feedback-samtaler kan vi derfor træne modellen på det nye datasæt og få det til at fungere.

Under udvikling af *pollendigitaliserings prototyper* har vi brugt den samme teknik som vi brugte under udvikling af *machine learning prototype*, hvor vi opretter konkrete opgaver til hver iteration som hjælper med at holde styr på processen.

Til den første iteration har vi oprettet et sprint som hedder *pollen digitalisering iteration.1*, hvor den vigtigste opgave var at få udviklet en holder til et webcam så den kunne stå på vores valgte stereolups mikroskop. Vi har uddelegeret opgaven til to medlemmer af gruppen som skulle udføre den. Efter prototypen var udviklet, har vi

foretaget en test af prototypen og givet feedback. Denne feedback førte os til at starte en ny sprint som hedder *pollen digitalisering iteration.2*.

I denne iteration har vi også identificeret opgaver som gruppen skal fokusere på, som er blevet faciliteret gennem Scrum. Den første opgave handler om at prøve et iPhone-kamera i stedet for et webcam, for at undgå webcams vidvinkel objektiv. Ved at benytte Scrum kan vi organisere denne opgave på en struktureret måde samt at udføre testene og evalueringen af det alternative kamera, før vi træffer beslutninger.

Den næste opgave indebærer at teste det nye kamera og evaluere dette, og ved hjælp af scrum kunne definere specifikke kriterier til hvad det nye kamera skal opfylde; såsom at kameraet skal kunne zoome ind, så vi kan se de forskellige pollen partikler og de kan blive genkendt af vores model.

Eftersom at feedback er en afgørende del af scrum processen, har vi inkluderet en opgave, hvor medlemmerne af gruppen giver feedback på det nye kamera og dets anvendelighed i prototyperne. Ved at bruge Scrum kan vores feedback blive indsamlet og integreret i vores iterative udviklingsproces. Denne feedback hjalp os med at identificere styrker og svagheder ved det nye kamera og guidede os til at træffe beslutninger.

Netværksteori / hvordan er vores vidensbidrag

Følgende afsnit går i dybden med projektets brug af netværksteori, og danner overblik over hvilke aktører projektet har interageret med for at skabe vidensdannelse, samt hvordan projektet inddrager den anti-disciplinære arbejdstilgang. Afsnittet fungerer også som en analyse til arbejdsopgave 5: "*Hvilken betydning har vores netværk haft på vores projekt, og hvordan bruger vi det?*", hvorpå vi gerne vil analysere hvilken betydning/indflydelse vores netværk har haft på vores produkt og Vidensdannelse, samt hvordan vi bruger det.

Anti-disciplinær videnskab i projektet

I vores projekt har vi skabt anti-disciplinær forskning ved at gruppens medlemmer både har undervist og vejledt hinanden baseret på vores forskellige erfaringer. Under dette, som vi også har nævnt i afsnittet om netværksteori, har vi formået at samle en masse fagfolk indenfor forskellige fagområder, der har bidraget til at samle vores viden. Vi har dermed samlet viden for forskellige områder igennem fagfolkene, som vi selv har fortolket til vores projekt. Herigennem har vi gjort brug af Fablab, der har været med til at facilitere det anti-disciplinære miljø, som har været med til at skabe en arbejdsproces, som er drevet af uformel projektbaseret vidensdeling. Vi tror på, at denne tilgang har hjulpet os med at udforske, samt at løse vores problemstillinger på en mere kreativ måde. Ved at anvende anti-disciplinær forskning i vores projekt håber vi at opnå en dybere forståelse af de komplekse sammenhænge og muligheder, der ligger inden for vores problemområde. Vi mener at denne tilgang har stimuleret nytænkning, skabe tværgående samarbejde og resultere i innovative løsninger, der ellers ikke ville være opnåelige gennem traditionelle disciplinære tilgange.

Hvordan bruger vi vores netværk

Vores projekt er blevet stærkt påvirket af vores netværk, og vores proces er blevet styret af de aktører som har været en del af projektet. Derfor mener vi at det er afgørende for forståelsen af projektet, at vi også forstå hvordan netværkets indflydelse spiller ind. Vi vil derfor i dette afsnit gå i dybden med at forstå vores netværk, og undersøge hvordan netværket har påvirket vores endelige produkt.

Triple A model

Vores opgave har været stærkt afhængigt af det netværk, vi har skabt i løbet af vores projektproces. Vi har valgt at undersøge hvordan vores netværk har påvirket vores endelige produkt, og hvordan de enkelte aktører har påvirket produktet med deres indflydelse. Her har vi valgt at bruge Triple A modellen (3XA) til at analysere netværkets indflydelse på vores endelige produkt.

Vi har lavet en visuel graf for at gøre relationerne overskuelige, hvilket samtidig vil bruges til at forklare hver enkelt relation og hvilken effekt relationerne har skabt. Vi har valgt at placere vores produkt/teknologi i midten af grafen, da det er den centrale faktor, som vores netværk arbejder omkring. Omkring den har vi herefter placeret de aktører som er en del af netværket og til sidst trukket pile mellem aktørerne for at vise relationer.

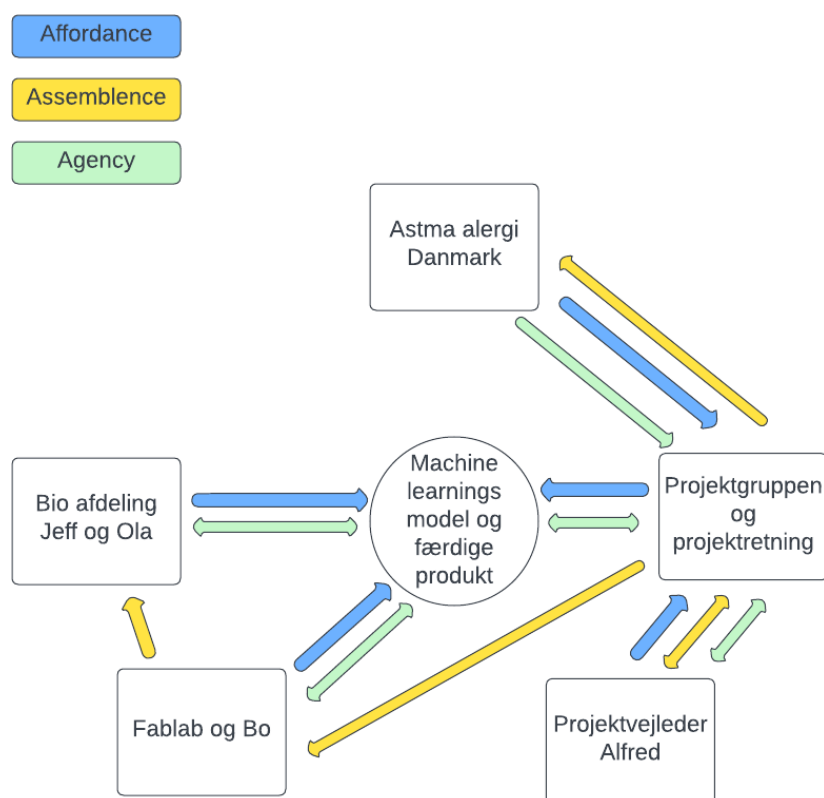


Fig 27. Ovenstående graf viser hvordan vi analysere vores netværk ved brug af triple A modellen

Til at starte med har vi en forbindelse med vores vejleder Alfred. Denne forbindelse er skabt gennem projekt dannelsen på RUC, og er skabt gensidigt, da forbindelse blev skabt som en del af den vilkårlige vejleder tildelings proces. Alfred har affordance over for vores projekt, indflydelse på vores projekt retningen, samt muligheden for at komme med input og forslag til vores proces. Den agency han bringer er de forslag han kommer med, og vi i projektgruppen har agency over Alfred igennem de beslutninger vi træffer, på baggrund af de forslag vi bliver givet.

Den første relation vi skabte var relationen mellem projektgruppen og Astma-Allergi Danmark. Her var det os, der forsøgte at skabe Assemblance, eftersom at det var os der kontaktede dem. Dette gjorde at Astma-Allergi Danmark fik Affordance over vores projekt retning da de havde muligheden for at hjælpe os med hvordan vi skulle gribe projektet an. De valgte at bruge deres Agency til at afslå samarbejde med os da de ikke havde tid og ressourcer, hvilket også medførte at de ikke har mulighed for at få Affordance eller Agency over for vores produkt.

FabLab var en vigtig aktør for at skabe et fysisk prototype, vi kunne bruge det til at tage billeder til vores model. Igennem Fablab fik vi en teknisk vejleder Bo, der hjalp os med vores projekt og var derfor mellemmand for projektgruppen og FabLab. Vi skabte kontakt til Bo, og efterfølgende da vi mistede muligheden for samarbejde med Astma Allergi Danmark hjalp han os med at få kontakt til en ekspert inden for den biologiske afdeling, nemlig Jeff. Fablab og Bo har haft en betydelig indflydelse på vores fysiske prototype, da det er dem, der har stillet ressourcerne, som mikroskop og petriskåle til rådighed, hvilket skaber affordance for dem til projektet. FabLabs og Bo's agency overfor produktet bliver herefter påvirket af det produkt som vi laver, da FabLab er et anti disciplinært miljø som ikke er eksperter inden for et bestemt felt. Derfor afhænger FabLabs feedback og hjælp, til hvilket produkt vi vil lave, samt vores produkt som bliver påvirket af hvad FabLab kan tilbyde.

Den biologiske ekspertise mistede vi da vi ikke kunne samarbejde med Astma-Allergi Danmark, hvorpå vi derfor søgte hjælp igennem andre fagpersoner inden for feltet, da vi gerne ville opnå en dybere forståelse for den biologiske del af pollen. Under dette fik vi hjælp af Bo fra FabLab til at oprette forbindelse til en ekstern lektor kaldet Jeff, som havde

en stor erfaring med pollen. Jeff gav gode input til hvad der var vigtigt at gøre, når man håndterede pollen, og var med til at oplyse relevante pollensæsoner, samt hvilke typer pollen der var relevante at samle. Jeff gav os også eksempler på lignende projekter, samt at give os en artikel, udført af eksperter med flere midler, der handlede om et projekt der ligner vores meget. Dette var med til at give os vores "open source vinkel", da det fik os til at tænke over hvad vi kunne bidrage med, som deres projekt ikke kunne. Jeff satte os også i kontakt med Ola Olsson, der var med på det andet projekt, men det var ikke nemt at holde kontakten, da den var ensidig.

Vores produkt er sat i midten og har pile til de aktører som har affordance og agency over udviklingen og processen. Her er det den biologiske del af netværket bestående af Jeff og delvist Ola, som vi har skabt gennem Fablab og Bo, samt os i gruppen, der har indflydelse på det færdige produkt. Produktet har også agency over de aktører der influerer produktet, da udviklingen af produktet har betydning for hvilke valg aktørerne laver. Et eksempel ville være at vi viste vores model til Jeff, der derefter ændrede sit input til at huske os på at vi skal være opmærksomme på svampesporer, når vi undersøger pollen. På den måde ændrede det Jeff's agency over produktet og de valg han træffer i forhold til input.

Kollaboration, Kooperation

I vores samarbejde har vi rettet fokus mod individuel udvikling inden for rammerne af fællesskabet, ved at gøre vidensdeling til en essentiel del af projektets progression. Vi har udnyttet vores individuelle ekspertise med det formål at opnå ny viden. I vores arbejde har vi bygget et netværk, hvoraf Jeff Ollerton og Bo Thorning blandt andet er en del af. Gennem samarbejdet med Jeff er vi blandt andet kommet frem til, at vores datasæt kunne inkludere svampesporer, da de ofte forurener den indsamlede pollen og besværliggør detektion og identifikation. Denne viden ville vi ikke have opnået uden Jeffs tilstedeværelse i vores netværk og vores fælles målsætning om at opnå ny indsigt. Dette blev dog ikke til en realitet, da vi i indsamlingsprocessen var uden for svampesporernes sæson. Som følge heraf har vi været i stand til at optimere vores model og opnå bedre resultater. På samme vis har vi delt ressourcer med Bo Thorning fra FabLab, som har forsynet os med de fysiske redskaber til at realisere vores projektidé. Denne "open

innovation" (*Budtz Pedersen, Martiny, Hansted & Wested, 2019, s. 24*) har gjort det muligt for os at arbejde i et dynamisk samarbejde, hvor målet var at opnå ny viden gennem vores prototyper ved at udnytte mulighederne for 3D-print og anvendelse af mikroskoper.

Eftersom vores projekt oprindeligt havde en meget teknisk tilgang, men vi har i fællesskab sammen med Alfred Birkegaard erkendt, at den humanistiske tilgang ikke var tilfredsstillende. Ved at analysere vores kollaborative arbejdsproces har vi derfor introduceret den humanistiske dimension. Den kollaborative tilgang læner sig yderligere op af vores open-source tilgang, hvor vidensdeling, samt vidensdannelse ofte er hovedprioriteten. På samme måde som open-source tilgangen kun fungerer på baggrund af en kollektiv indsats, tager vores projekt og vidensdannelse rod i et fælles ansvar og mål om at udvikle og danne ny viden.

Diskussion

Vi vil i dette afsnit gennemgå vores resultater, som vi er kommet frem til gennem analysen, og diskutere hvad disse resultater har betydet for vores endelige projekt. Afsnittet kommer til at diskutere kvaliteten af vores endelige produkt, hvilket vidensbidrag det har medført, og hvordan vores netværk har influeret projektet.

Produkt Diskussion

I dette afsnit vil der diskuteres om, hvordan vores projekt bidrager med nye tilgange indenfor objektgenkendelse af pollen, og hvordan vi forventer at vores endelige produkt kommer til at bidrage til fremtidig udvikling. Afsnittet vil derfor også afrunde arbejdsspørgsmål 4: *“Hvor godt løser vores produkt sin opgave, og hvad bidrager det med?”*.

Et aspekt der påvirker vores projekt er det manglende samarbejde med Astma-Allergi Danmark, da det gør at vi ikke kan sætte os nogle mål for vores teknologi. Med dette menes der at vi ikke rigtig har nogen mulighed for at få en konklusion af teknologien, da vi ikke har et mål hvorpå vores projekt kunne bruges i praksis. Dette gør derfor at vi ikke kan konkludere vores projekt, da vi har en manglende kontakt i vores netværk hvorpå vores projekt kan vurderes. Under dette ved vi ikke rigtig hvad der præcis sker i Astma-Allergi Danmarks arbejdsprocesser og kan derfor ikke sætte vores projekt ind i en boks hvorpå det kan hjælpe disse arbejdsprocesser. På samme måde har vores open-source tilgang ikke et stort konklusions potentiale, da vi ikke kan konkludere vores projekt ud fra subjekter, der ønsker at arbejde med vores open-source tilgang, hvorpå disse personer højst sandsynligt ikke er fagpersoner og kan vurdere vores produkt ordentligt.

Ved at gøre vores proces til et open-source projekt, har andre mulighed for at enten gå videre med ideen, og inkludere andre typer af pollen, eller at bruge modellen til at genkende pollen og få en ide, om hvilke type pollen det er. Vores model er god til at identificere, men dårligt til at klassificere, grundet forskellige variationer indenfor det

samme pollentype, som vi har set med mælkebøtte-pollenen, som ender i at vores model har vanskeligheder med at klassificere dette. Dette betyder at vores model ikke er den perfekte løsning, og at der stadig er plads til forbedringer og tilføjelser. Derfor opfordre projektet til videreudvikling igennem open-source konceptet, og fungere som inspiration til hvordan en machine learning model ville kunne laves og trænes.

Vi ved at der allerede findes eksempler på objektgenkendelse inden for pollen partikler igennem Ola Olson artikel; *Efficient, automated and robust pollen analysis using deep learning (Olsson, 2021)* og vi ved derfor også at vi ikke kommer med en ny og revolutionerende løsning. Vores formål er derimod at vise en anden tilgang til en løsning, som ikke kræver de samme ressourcer og som er mere tilgængelig for normen.

Produktets bidrag

Vores projekt viser at machine learning er nået til et punkt hvor tilgængeligheden tillader ressourcessvage projekter stadig at tage den i brug. Det har en demokratiserende effekt, når teknologi bliver tilgængeligt for flere. Dette er målet med at bruge open source til at dele vores viden, facilitere bedre brug af teknologien og forståelse for vigtigheden af et projekts situation. Vores projekt passer på European Citizen Science Associations redegørelse for begrebet Citizen Science, og vi hjælper den generelle befolkning med at deltage i videnskabelige processer. Vores projekt understøtter brugen af objektgenkendelse og at bringe det ind i "virkeligheden", gennem mikroskop, og vores projekt både udforsker muligheder, samt kan bruges til at forme senere videnskab.

Vi bruger vores eksempel med objektgenkendelse med YOLOv8 som eksempel på at Machine Learning er nået til et stadie før dens simplicitet gør den let tilgængelig, men efter at specialistviden er nødvendig for dens anvendelse. Afhængig af den specifikke machine learning man vil bruge, er forståelses kravene mindre eller højere, men centralt ligger tilgængeligheden af viden om de specifikke teknologier og deres brug.

Grundet dette har vi også forsøgt at yde fuld transparens om vores proces og vores netværk, fordi tilgængeligheden om teknologiens brug bevæger den i en demokratisk og citizen science støttende retning.

På baggrund af vores projekt kan man konkludere at det er muligt at digitalisere via mikroskopbilleder og derefter træne objektgenkendelses modeller på billederne. Dette har en lang række praktiske use cases, som projektet blev inspireret af; blandt andet blodcelle detektion og klassificering. Yderligere findes en alternativ retning vores projektgruppe diskuterede, klassificering af svampespore - eller en oplagt brug af vores konkrete projekt i en Citizen Science sammenhæng er at tillade den generelle befolkning at lave pollen tælling lokalt. Det ville betyde at pollentælling kunne være lokalt og mere aktuelt for den enkelte. Brugen af objektgenkendelse under mikroskop har voldsomt stort potentiale. Som kompleksiteten af billeder stiger vil produktivitetsindvirkningen af modellerne også stige. Det er her hvor vores projekt viser barrieren som kompleksitet spiller i en problemstilling, derfor bliver mindre jo bedre tilgængeligheden machine learning har. Samtidig med at tilgængeligheden af eksisterende værktøjer stiger, vil den formentlige udvikling af nye værktøjer forbedre muligheden for at håndtere mere og mere komplekse opgaver, med færre og færre forudsætningskrav for projektgrupper.

Anti disciplinær arbejde vs Allergi Danmark

Et essentielt punkt at tage stilling til er hvem vores stakeholders vi gerne vil udvikle vores teknologi til. Under dette har forskellige stakeholders forskellige faglige niveauer og ambitioner de gerne vil bruge vores teknologi til. For at tage stilling til dette kan vi sætte Astma-allergi Danmark og en givende forsker som stakeholder op imod hinanden for at belyse deres forskellige interesser for teknologien. Astma-Allergi Danmark er her en dansk sundhedspolitisk organisation og har kørt deres organisation i mange år manuelt. Det betyder derfor at hvis en form for machine learning bliver sat i kraft i deres virksomhed, kan dette drastisk påvirke deres arbejdsprocesser og miljø, da det tilbyder et skift i deres arbejdsprocesser. Dette kan derfor betyde at de er lidt mere påpasselige i hvad de vælger at indføre, hvorpå man kan diskutere deres rolle i organisationen kan være i fare i form af en indførelse af en ny teknologi.

På den anden side har vi forskeren, eller vores projektgruppe, som stakeholder, der har andre ideologier end Astma Allergi Danmark har. Forskeren er tit kun fokuseret på at opnå ny viden indenfor det felt, de vælger at udforske, lige meget hvilke arbejdsprocesser eller påvirkning dette har på feltet. Dette lægger sig derfor mere op af den anti-disciplinære

arbejdstilgang, da vi som projektgruppe er med til at samle forskellige fagpersoners viden i et samlet initiativ til at opnå ny viden indenfor vores problemfelt. Forskere eller fagpersoner er derfor mere åbne overfor at belyse viden og hjælpe arbejdsprocessen, da det ikke ville påvirke dem som i en organisation som Astma-Allergi Danmark. Det kan her diskuteres, om Astma-Allergi i Danmark bevidst vil holde data eller viden om organisationen tilbage, eftersom de gerne vil beholde deres gamle arbejdsprocesser og ikke er interesseret i forandring.

Netværk

I dette afsnit kommer vi til at diskutere hvordan vores valg af netværk har haft betydning for projektets retninger, og tager udgangspunkt i vores behandling af agile og kollaborativ udvikling. Derefter vil vi diskutere forholdet mellem kollaboration, samt Kooperation, og hvordan vi har brugt de forskellige tilgange, samt at diskutere pollen samfundet og dets sammenhæng til kognitiv kapitalisme. Dette afsnit vil derfor diskutere arbejdsspørgsmål 5: *“Hvilken betydning har vores netværk haft på vores projekt, og hvordan bruger vi det?”*, hvorpå vi gerne vil diskutere hvilken betydning vores netværk har haft på vores produkt, samt hvordan vi bruger det.

Agil udvikling vs Kollaborativ udvikling

Som en del af vores arbejdsproces har vi arbejdet med flere forskellige tilgange til projekt og produkt udvikling, hvorpå vi har brugt den agile SCRUM metode til at facilitere vores møder og feedback, mens vi har arbejdet kollaborativt for at tilpasse vores netværk og etablere vores vidensdannelse. Den agile proces bliver defineret som værende en strømlinet proces hvor der er klare mål og opdelinger for hvem der skal gøre hvad, og hvornår. Der er her fokus på, at de individuelle aktører *“kontinuerligt kommunikerer og afstemmer deres delplaner, handlinger i forhold til det overordnede mål.”* (Budtz Pedersen, Martiny, Hansted & Wested, 2019). Hvilket er meget sammenligneligt med vores SCRUM process, og den kooperative tilgang til problemløsning. Vi har yderligere

brugt den kollaborative tilgang i vores arbejdsproces, til at facilitere vidensdannelse og fælles forståelse gennem vores produktudvikling og design, samt rapportskrivningsprocesser. I vores kollaborative arbejdsproces er det problemløsningen, der er i hovedsædet, samt dannelse af en ny kollektiv forståelse.

Ved første øjekast er der en kontrast mellem de to tilgange, hvordan vi har brugt dem til projektudvikling. Hvordan kan man agere kollaborativt igennem en generelt agil proces som SCRUM, der traditionelt lægger sig så tæt op i et kooperativt samarbejde?

Den agile tilgang vægter præcision, deadlines og læner sig op af en fælles forståelse for målet med arbejdet. Projektet har selektivt udvalgt dele af den agile tilgang, for at danne et overblik over projektets delmål, samt opnå en kollektiv forståelse for målet med vores projekt. Gruppen har valgt at opdele og uddelegere dele af projektet, der ikke krævede at alle seks gruppemedlemmer var en del af det, og har på den måde arbejdet agilt.

Yderligere agerer projektet i et netværk af ekspert personer, indenfor både fysisk produkt udvikling og pollen-viden, der har gjort det muligt at bruge både netværket, men også projektets deltagers egne individuelle kundskaber og videns-punkter til at danne en ny kollektiv forståelse for videns-målet med projektet. Her argumenteres, på baggrund af ovenstående, for at projektet har balanceret og udvalgt dele af begge tilgange, for at skabe det bedst fungerende arbejdsmiljø for denne gruppe specifikt. Pedersen et al definerer i deres bog, at kollaborativ som værende: *“den sociale læring, forløbet og processen i problemløsningen”* (Budtz Pedersen, Martiny, Hansted & Wested, 2019).

Vores kollaboration har lagt meget vægt på kollektiv forståelse, værende både faglig og praktisk, hvilket nødvendigvis ikke er Vidensdannelse, eller eksklusivt for kollaboration, men er nødvendig for videre Vidensdannelse. Vores kollaborative arbejde skyldes, at den individuelle viden bliver fælles, hvilket danner grundlag for yderligere viden.

Så hvordan agerer vi kollaborativt i den agile arbejdsproces? Det gør vi blandt andet ved at være opmærksomme på, at når vores produktivitet gennem den agile proces, har overhalet vores kollektive forståelse, har det været nødvendigt at arbejde mere kollaborativt, for at genskabe den kollektive forståelse. Vi argumenterer på baggrund af dette for, at vi har udviklet en specifik hybridmodel til vores arbejdsproces, som har faciliteret vores produkt- og rapport-udvikling. Denne model har vi gjort brug af, når vi har afholdt ugentlige SCRUM møder har arbejdet agilt og uddelegeret konkrete arbejdsopgaver, som efterfulgt af en kollaborativ process hvor vi gennem dialog og diskussion har skabt forståelse som vi

har brugt til at drage konklusioner. Der argumenteres yderligere for, hvordan vi har skabt vores egen iterative proces, hvor der løbende har været skift mellem Kooperation og Kollaboration.

Gennem vores arbejde fandt vi at selvom Kollaboration er den bedre videnskabelige organisering i forhold til videndannelse, er samarbejde nødvendig for produktion. Vi argumenterer for, at universitetsprojekter er overordnede resultat orienteret, og det af den grund er umuligt for vores proces at arbejde udelukkende Kollaborativt. Vidensdannelse er nødvendig for et godt projekt, men selve projektet, rapporten og produktet, er et resultat af en kooperativ samarbejdsproces.

Hvor stor betydning har vores netværk på projektet

Vores projekt som tidligere nævnt, har været stærkt påvirket af det netværk vi har skabt, både ressource og retningsmæssigt. I analysen kommer vi frem til at vores projekt ikke ville kunne genskabes uden også at skabe et lignende netværk - men hvordan hænger vores projekt sammen med pollensamfundet og ideologien om, at viden er en fri ressource? Hvordan ville vores projekt have set ud, hvis vi havde haft et andet netværk, eller et samarbejde med Allergi Danmark?

Det produkt vi har skabt og det fokus vi har lagt på open source aspektet af projektet, betyder også at projektets fokus ligger på vidensdeling. Det er derfor muligt at drage paralleller til teorien om pollen samfundet hvor alle bidrager med viden, og Vidensdannelse er en vare der skal være frit tilgængelig for at skabe vækst og fremgang. Dog ville det også være muligt at projektet havde fået et helt andet fokus hvis vi havde skabt et samarbejde med Astma-Allergi Danmark. Hvis dette havde været tilfældet ville vores projekt muligvis have haft en anden retning, og frem for at dele viden og arbejde i et anti-disciplinært miljø, ville vi i stedet have fokus på at forbedre arbejdsprocessen og skifte vores Kollaborative tilgang ud med den kooperative. Vi ville stadig få input fra Astma Allergi Danmark, men formålet for dem til forskel for Boutang, ville være at skabe en bedre og mere effektiv proces for dem selv, frem for at skabe ny viden.

Vores forsøg på at agere i et Kollaborativt samarbejde med Astma Allergi Danmark blev ikke realiseret, og der kan være mange grunde til det. Hvis man anskuer det gennem Jeff

Ollerton svar på den kognitive kapitalisme, kan man se at vores Vidensdannelse blev begrænset på baggrund af videns værdi. Når viden har økonomisk værdi, bliver man nødt til at holde den viden inden for sig selv, hvilket resulterer i netværk som er svære at penetrere. Det er i Astma-Allergi Danmark's interesse at holde på viden, og det er ikke økonomisk rentabelt at sætte timer af til at arbejde sammen med os. Hvis vi var uden for den kognitive kapitalis indflydelse, og en del af pollen samfundet ville vores forsøg på at samskabe viden med Astma-Allergi Danmark resultere i vores inklusion i deres netværk. Vi ville kunne bruge deres viden, fordi den Vidensdannelse vi kunne lave sammen, ikke fratog dem noget økonomisk.

Vores projekt tog derfor en anti-disciplinær tilgang, vi blev ikke tilladt adgang til netværket, men brugte så Fablab til at etablere en proces, så vi alligevel kunne løse vores opgave. Dette står i modsætning til den proces som pollensamfundet beskriver, hvor vi havde indgået i en Vidensdannelsesproces frit og sammen med andre, meget lig en kollaborativ proces. En pointe som er værd at nævne er, at den kognitive kapitalismes indflydelse skaber lukkede netværk, som direkte ledte os til at anskue netværks betydning for vidensskabelse. Derfor kan man argumentere for at den kognitive kapitalisme er skyld i dens egen observation. Med det nævnt har vi før pointeret at Vidensdannelse fordelagtigt bruger kollaboration, men at den produktivitet som cooperation faciliterer er nødvendig for videnskabens applicering.

Vores projekt eksemplificerer hvordan netværk spiller ind på Vidensdannelse. I vores projekt blev vi fraholdt adgang til AAD netværket, mens på grund af Hum-Teks forbindelse til FabLab kunne vi let tilgå FabLab netværket. FabLab har en anti-disciplinær tilgang som tillod os at fuldføre vores projekt alligevel. Når vi forsøger at penetrere et netværk, vi ikke indgår i, er det anti-disciplinært. Den viden, og det produkt vi fik skabt, har en helt anden form, når den bliver lavet gennem det netværk som vi fik etableret gennem Fablab. Det er muligt, at vi måtte omforme vores problemfelt, hvis vi havde stået uden for FabLab netværket. Når man så anser vores projekt som et forsøg på at open-source viden om machine learning under mikroskop, er vores anskuelser om at netværket har central betydning for projektets form, vigtigt at fremvise. Hvis man vil eftergøre vores proces i en anden sammenhæng, måske hos en anden organisation, bliver man nødt til at gennemgå sit netværk og dets muligheder, samt om det er muligt at udvide det, for at skabe mulighed for kollaboration hvor vidensudbyttet er det som projektet kræver. Foregående viser en

pointe om, at man som projektgruppe må stille sig selv spørgsmålet: Ud fra de muligheder vi har, hvordan kan vi udvide vores netværk bedst? Der ligger en arbitrær undertone, for det vil altid være vilkårligt, hvilket netværk en given projektgruppe har i et projekts start. Vores projekt viser at det netværk man har til at starte med kan udvides, at det er ikke alle netværk man kan trænge ind i, og de netværk man trænger ind i har stor betydning for den Vidensdannelse man kan lave. Det endelige projekt er formet af det endelige netværk man er for skabt.

Pollensamfundet

Gennem vores projekts forløb blev vi netværks bevidste, hvorpå vi indså den betydning som et netværk har for vidensdannelse og som et led af dette blev vi introduceret til pollensamfundet. Vores erfaringer med kollaboration er vidensskabende og problemløsende samarbejder, som kan drages til sammenligning med det vidensdannende ideal for pollensamfundet. Når pollensamfundet søger fri "pollinering" mellem arbejderbier, her værende vidensskabende arbejdere som forskere eller studerende, søges der en fri kollaboration på tværs af netværk - en ophævelse af netværk, som resulterer i at vidensdannelse kan ske uden barriere. Barriere som vi også har oplevet i vores projekt. De barriere viser vi også gennem projektet, og de spiller formgivende roller i vores projekt. Denne vidensdannelse uden netværk, som der søges i pollen samfundet, sætter vi lig med beskrivelsen om kollaboration. Kollaborationens vidensskabende fordele, oplevede vi konkret i vores projekt, men også nødvendigheden af brugen af Kooperation, som er en arbejdsprocess som ikke bliver beskrevet i Axel's fortælling af pollensamfundet. Derfor må vores praktiske erfaringer om at Kooperation skaber resultater, altså målbare konkrete opgaver, der inkorporeres i pollen samfundets vision om fri vidensdannelse. Vores erfaringer er at vidensdannelse kræver resultatbaseret arbejde og kooperativt samarbejde er derfor også nødvendig. Her kan man vidredrage fra vores hybridmetode at det formentlig også vil være nødvendigt at sikre resultatorienterede mekanismer i et svar til den kognitive kapitalisme, da vidensdannelse i sig selv ikke alene kan resultere i en samfunds-forbedring. Med dette må det pointeres at vores erfaringer ikke er en total opdeling eller dikotomi mellem resultater og vidensdannelse i Kooperation og kollaboration. Vi har erfaret i vores projekt at Kooperation har skyldt overvejende

resultatorienteret arbejde, hvor den primære vidensdannelse er sket igennem kollaborative processer.

Her er opdelingen ikke fuldkommen, begge samarbejdsmetoder har hver skabt resultater enten gennem rapportskrivning med Kooperation, eller udvikling af prototyper for Kollaboration. De har også begge bidraget til vidensdannelse gennem vidensindsamling Kooperationelt, og kollektiv forståelse samt sammensætning af indsamlet viden gennem diskussioner i en kollaborativ process. Her kan man også pointere at opdelingen af Kooperation og Kollaboration kræver tolkning, da samarbejdsformerne kan være svære at adskille. Men efter vores foregående forståelse kan det måske også være fordelagtigt at stræbe efter ikke at adskille dem, da et hybrid samarbejde måske vil være at foretrække, da vi foregående har anerkendt, at hver arbejdstype har styrker og svagheder. Vores projekt anerkender det videnskabende potentiale som Pollen samfundet bestræber, da vi har oplevet lignende arbejdsprocesser i vores Kollaboration både internt i gruppen og med vores eksterne samarbejdspartnere.

Vores mål er ikke at afkræfte Pollen samfundet som ide, blot at pointere at vores projekt har vist at vidensdannende aktivitet også skal understøttes med resultat producerende arbejde, og at det nødvendigvis må indtænkes i det ideelle videnskabende samfund, som Pollen samfundet. Vores erfaring er, at fordi at Pollen samfundet er beskrevet i kraft af den kognitive kapitalisme, og er et svar på dynamikkerne dertil, kan dens ideal om

Vidensdannelse stadig videreudvikles, fordi det aldrig har stået for sig selv og ikke er en aktuel samfundssituation nogen steder. Når man læser Yann Moulier-Boutangs Cognitive Capitalism kapitel 7: "Envoi: A manifesto for the Pollen Society", står det klart at Pollen samfundet bestemt er opfundet som svar til den kognitive kapitalisme. Vores bidrag her er, at Pollen samfundet kan udredes mere i dybden, hvilket endegyldigt betyder at den må videreudvikles. Selv uden en indførelse af et Pollen samfund og nedrivning af den kognitive kapitalisme, bidrager viden om et ideelt videnssamfund til, hvordan man helt konkret i vores samfund kan forsøge at efterleve det i praksis. Derfor er Pollen samfundet og dens udvikling stadig vigtig, selv hvis man ikke vælger at afmontere kapitalismen i samfundet.

Konklusion

I dette afsnit ønsker vi at samle og konkludere hovedpointerne i vores projekt, samt at samle de delkonklusioner vi er nået frem til for at opsummere hele vores projekt. Dette vil vi gerne gøre ved at inddrage vores problemformulering, samt arbejds spørgsmål, men også fremhæve vigtige pointer fra opgaven for at konkludere hvor godt vores projekt har lykkedes. Vi startede dette projekt ved at spørge om:

“Hvilken betydning har et netværk der faciliterer samarbejde og vidensproduktion, for at udvikle en objektgenkendelses model til detektering og klassificering af pollen partikler, med det formål at udvise transparens og efterlignelighed i en open-source process?”

For at besvare den, har vi gennemgået vores baggrund for projektet, relationen til Astma-Allergi Danmark og deres arbejdsprocesser. Vi har beskrevet vores netværk, samt vores motivation som har dannet baggrunden for vores projekt. Vi erkender os en open-source tilgang som har resulteret i en transparens i vores netværk og vores beslutninger. Samt beskriver Fablab og den antidisciplinære tilgang som vores projekt har.

Vi har af den grund også gennemgået vores styring af projektet for at redegøre for vores process, men også senere analyseret og diskuteret dens betydning. Her har vi gennemgået struktureringen af samarbejde internt i gruppen, gennem begreberne kollaboration og Kooperation. Vi konkluderer på baggrund af vores SCRUM projektstyring at kollaborativt samarbejde er vidensskabende, men at kooperativt samarbejde er nødvendigt i resultatorienterede sammenhænge.

Vi har redegjort for objektgenkendelse, dens evne til at detektere og klassificere objekter på billeder, og senere brugt det i vores produkt. Der bliver vist vores prototyper, hvad de har betydet for projektet og forklaret hvordan vi har brugt YOLOv8 på vores digitalisering af pollen under mikroskop. Vi gennemgår hvordan vi har brugt den og videreudviklet vores prototyper gennem en iterativ proces.

Efterfølgende har vi evalueret både teknisk og praktisk, hvor resultaterne har været en machine learning model som i nogen grad vil kunne forbedre pollenoptællingsprocessen. I forhold til dette er det også vigtigt at pointere at vores produkt i form af vores machine learning model, ikke på dette tidspunkt kan evalueres ud fra den arbejdsproces som inspirerede dens ophav. Under dette kan vi ikke afprøve vores produkt hos Astma-Allergi Danmarks arbejdsprocesser for at teste om det kan gøre deres arbejde nemmere, eller teste det på en person der er interesseret indenfor feltet igennem vores open-source tilgang. Vi kan derfor kun give et gæt på hvordan vores produkt ville fungere i praksis igennem hvad vores egen teori, vidensgrundlag og metoder peger ind på. Vores tekniske analyse viser at vi har lavet en model som i nogen grad kan detektere og klassificere pollen, hvor den varierer i effektivitet afhængig af pollentypen. Det viser også at detektering- og klassificerings -opgaver godt kan løses med objektgenkendelse.

Vi har derudover analyseret vores netværk, og vist dens betydning for vores projekts form, samt hvordan det har spillet en central rolle for vores vidensdannelse. At vi ikke kan tilføje Astma-Allergi Danmark til vores netværk, resulterer i en anti-disciplinær tilgang som også spiller ind i vores vidensdannelse. Vores open-source tilgang til projektet har ledt os til at have et transparent overblik over de muligheder, vores netværk har skabt for os, med det formål at andre kan bruge vores erfaringer til deres projekter. Dette fører os til en konklusion om vigtigheden af netværk i et projekt, og erkendelsen om betydningen af et netværk for ny viden.

Ovenstående fører os til den endelige konklusion på vores problemformulering; at betydningen af netværk har været en central del for projektets vidensdannelse, da det har faciliteret arbejdsprocessen, samt spiller en rolle for projektets endelige form. Yderligere konkluderer projektet, at det er muligt at skabe en objektgenkendelsesmodel gennem et anti-disciplinært samarbejde, som er efterligneligt og tilgængeligt, med det formål at give andre indsigt i vores process hvilket agere som værktøj der vil hjælpe med lignende projekter.

Til sidst har vi planer om at kontakte Astma-Allergi Danmark og vise vores endelige produkt for at høre om, vores endelige produkt kunne hjælpe dem i deres arbejdsprocesser. Dette har vi tænkt os at gøre for give et bedre bud på en evaluering af vores produkt, samt at få noget feedback som vi kunne bruge til eksamen.

Referencer

- Astma-Allergi Danmark. (n.d.). *Om Organisation*. Astma-Allergi Danmark. From <https://www.astma-allergi.dk/om-os/organisation/>
- Astma-Allergi Danmark. (n.d.). *Pollenkalender - Overblik over pollensæsonen*. Astma-Allergi Danmark. From <https://www.astma-allergi.dk/pollenservices/pollenkalender/>
- Agrawal, S. (2021, May 17). How to split data into three sets (train, validation, and test) And why? Towards Data Science. From <https://towardsdatascience.com/how-to-split-data-into-three-sets-train-validation-and-test-and-why-e50d22d3e54c>
- Basili, V., & Larman, C. (2003, June). *History of iterative and incremental development*. I A. Cockburn & L. Williams (Red.), IEEE Computer. From <https://wiki.c2.com/?HistoryOfIterative>
- Bhattacharyya, J. (2020, October 11). *Step by Step Guide To Object Detection Using Roboflow*. Analytics India Magazine. From <https://analyticsindiamag.com/step-by-step-guide-to-object-detection-using-roboflow/>
- Brownlee, J. (2017, July 14). *What is the Difference Between Test and Validation Datasets? - MachineLearningMastery.com*. Machine Learning Mastery. From <https://machinelearningmastery.com/difference-test-validation-datasets/>
- Burns, E. (2021, March 30). *What is machine learning and why is it important?*. From <https://www.techtarget.com/searchenterpriseai/definition/machine-learning-ML>
- Budtz Pedersen, D., Martiny, K. M., Hansted, A. B., & Wested, J. (2019). *Kollaboration: Vejen til åben forskning og åben innovation*. Samfundslitteratur.

- Deppakat 002. (n.d.). *yolov8*. " - Wiktionary. From <https://github.com/deepakat002/yolov8/tree/main>
- DewangNautiyal. (2023, February 20). ML | *Underfitting and Overfitting*. From <https://www.geeksforgeeks.org/underfitting-and-overfitting-in-machine-learning/>
- Niels Jørgensen (2018, December 17). *En eksemplarisk analyse af teknologis indre mekanismer og processer*
- DMI. (n.d.). *Dagens pollental DMI*. DMI. From <https://www.dmi.dk/pollen/>
- Drumond, C. (n.d.). *Scrum - What is it, how it works, & how to start*. Atlassian. From <https://www.atlassian.com/agile/scrum>
- Eby, K. (2023, January 5). *The Power of Iterative Design and Process*. Smartsheet. From <https://www.smartsheet.com/iterative-process-guide?fbclid=IwAR3Lu1M-QbpjujsfWnALLtwk9FqcAE-w2iWzcOzAxDn9Ehpe6OkKMUVetmo>
- FabLab. (n.d.). *FabLab about*. Fablab RUC. From <https://fablab.ruc.dk/about/>
- FOTA. (2021, March 19). *The Humble Dandelion*. Fota Wildlife Park. From <https://www.fotawildlife.ie/news/the-humble-dandelion/>
- Gulbrandsen & Just.(nd) *Strategizing Communication: Theory and Practice*. Chapter 09: *Social and Material*. From <https://moodle.ruc.dk/mod/resource/view.php?id=433404>
- ik1xpv. (2020, January 01). *SMD viewer using a Logitech BRIO 4k by ik1xpv*. From <https://www.thingiverse.com/thing:4078649>

- IBM. (n.d.). *What is machine learning?*. IBM. From <https://www.ibm.com/topics/machine-learning>
- Javatpoint. (n.d.). *Data Preprocessing in Machine learning*. Javatpoint. From <https://www.javatpoint.com/data-preprocessing-machine-learning>
- Jocher, G. (n.d.). *ultralytics*. GitHub. From <https://github.com/ultralytics/ultralytics>
- Johnson, S. (2023, April 28). *What Is Prototype Theory?* AllTheScience. From <https://www.allthescience.org/what-is-prototype-theory.htm>
- Khanzhina, Natalia, et al. "*Combating data incompetence in pollen images detection and classification for pollinosis prevention.*" *Computers in biology and medicine* 140 (2022): 105064. From <https://www.kaggle.com/datasets/nataliakhanzhina/pollen201det>
- Kristensen, J. E. (2009, May 1). *Kognitiv kapitalisme, vidensøkonomi og videnspolitik*. Turbulens.net. From <https://turbulens.net/kognitiv-kapitalisme-vidensoekonomi-og-videnspolitik/>
- Kundu, R. (2023, January 17). *YOLO Algorithm for Object Detection Explained [+Examples]*. V7 Labs. From <https://www.v7labs.com/blog/yolo-object-detection>
- Lopes, S. A., Bergamo, P. J., Najara Pinho Queiroz, S., Ollerton, J., Santos, T., & Rech, A. R. (2022). *Heterospecific pollen deposition is positively associated with reproductive success in a diverse hummingbird-pollinated plant community*. *Oikos*. Advance online publication. From <https://doi.org/10.1111/oik.08714>
- Mannaz. (n.d.). *Hvad er scrum? | Kurser og certificeringer i Scrum*. Mannaz. From <https://www.mannaz.com/da/kurser-og-uddannelser/projektledelse/scrum/>

- May 2012, [www.dpi.nsw.gov.au/publications/updates Primefact 1126 second edition](http://www.dpi.nsw.gov.au/publications/updates/Primefact%201126%20second%20edition) Agriculture NSW FACTSHEET Pollen trapping and storage Doug Somerville, Technical Specialist Honey Bees, Goulburn
- Microsoft Azure. (n.d.). Hvad er Computer Vision? Microsoft Azure. From <https://azure.microsoft.com/da-dk/resources/cloud-computing-dictionary/what-is-computer-vision/>
- Ollerton, J. (n.d.). *About*. Prof. Jeff Ollerton. From <https://jeffollerton.co.uk/about/>
- Oxford Reference. (n.d.). *Prototype theory*. prototype theory. From <https://www.oxfordreference.com/display/10.1093/oi/authority.20110803100351197?jsessionid=78611A14BCF67D37FC855ED95CE62EB6>
- Olsson, O, Karlsson, M, Persson, AS, et al. Efficient, automated and robust pollen analysis using deep learning. *Methods Ecol Evol*. 2021; 12: 850– 862. <https://doi.org/10.1111/2041-210X.13575>
- Petersen, L. A. (2009, May 1). *Bibemærkningerne til den kognitive kapitalisme*. Turbulens.net. From <https://turbulens.net/bibemaerkninger-til-den-kognitive-kapitalisme/>
- Rajput, A. (2023, January 5). *All About Iterative Design*. UXmatters. From https://www.uxmatters.com/mt/archives/2023/02/all-about-iterative-design.php?fbclid=IwARoCQ43SIav7LjmUh3QJj5pEbr7FLUcSb2_xVGjB4r5lwv1DZvMf-673Jak
- Roboflow. (2022, September 29). *Annotate*. Roboflow. <https://docs.roboflow.com/annotate>
- Roboflow. (2022, December 02). *Merge Projects/Datasets*. Roboflow. From <https://docs.roboflow.com/merge-datasets>

- Roboflow. (2023, February 01). *Adding Team Members to a workspace*. Roboflow. From <https://docs.roboflow.com/roboflow-workspaces/adding-team-members-to-a-workspace>
- Roboflow. (2023, March 16). *Overview*. Roboflow. From <https://docs.roboflow.com/>
- Roboflow. (2023, April 28). *Dataset Health Check*. Roboflow. From <https://docs.roboflow.com/dataset-health-check>
- Roboflow. (2023, May 04). *Image Preprocessing*. Roboflow. From <https://docs.roboflow.com/image-transformations/image-preprocessing>
- Roskilde University. (n.d.). *Humanistisk-Teknologisk Bachelor*. Roskilde Universitet. From <https://ruc.dk/bachelor/humanistiskteknologisk-bachelor>
- Roskilde University. (n.d.). *Problemorienteret projektlæring - Roskilde Universitets pædagogiske model*. Roskilde Universitet. From <https://ruc.dk/problemorienteret-projektlæring-roskilde-universitets-pædagogiske-model>
- Simpleilearn. (2023, May 24). *What is JIRA?: How to Use Jira Testing Software Tool*. Simplilearn. From https://www.simplilearn.com/tutorials/jira/what-is-jira-and-how-to-use-jira-testing-software#what_is_jira
- Skytt, L. (2023, March). *Kunstig intelligens*. Faktalink. From <https://faktalink.dk/titelliste/kunstig-intelligens>
- Thorning, B. (2020, March 23). *Artificial intelligence in a microscope. "* - Wiktionary. From <https://fablab.ruc.dk/artificial-intelligence-in-a-microscope/>

- Visual Paradigm. (n.d.). *What is Product Owner's Role in Scrum? - Product Owner*. Visual Paradigm. From <https://www.visual-paradigm.com/scrum/what-is-project-owner-role-in-scrum/>
- Visual Paradigm. (n.d.). *What is Scrum Team? - Scrum Guide*. Visual Paradigm. From <https://www.visual-paradigm.com/scrum/what-is-scrum-team/>
- Vohland, Vohland, K., Land-zandstra, A., Ceccaroni, L., Lemmens, R., Perelló, J., Ponti, M., Samson, R., & Wagenknecht, K. (2021). *The Science of Citizen Science* (Vohland, A. Land-zandstra, L. Ceccaroni, R. Lemmens, J. Perelló, M. Ponti, R. Samson, & K. Wagenknecht, Eds.; 1st ed. 2021.). Springer Nature. From <https://doi.org/10.1007/978-3-030-58278-4>
- Wolfewicz, A. (2022, November 16). *How Do Machines Learn? A Beginners Guide*. Levity AI. From <https://levity.ai/blog/how-do-machines-learn>
- Wolfewicz, A. (2023, February 15). *Deep Learning vs. Machine Learning – What's The Difference?* Levity AI. From <https://levity.ai/blog/difference-machine-learning-deep-learning>